

Modelo de aprendizaje automático para la detección de anomalías asociadas al Lavado de Activos basado en el algoritmo Isolation Forest

David Santiago Ovalle Caviedes

Facultad de Ingeniería
Departamento de Ingeniería de Sistemas e Industrial
Sede Bogotá, Colombia
2026

Modelo de aprendizaje automático para la detección de anomalías asociadas al Lavado de Activos basado en el algoritmo Isolation Forest

David Santiago Ovalle Caviedes

Tesis presentada como requisito parcial para optar por el título de:
Magíster (M, MSc) en Ingeniería de Sistemas y Computación

Director(a):
Dr. Jorge Eliécer Camargo Mendoza
Profesor Asociado -
Facultad de Ingeniería
Universidad Nacional de Colombia

Universidad Nacional de Colombia
Facultad de Ingeniería
Departamento de Ingeniería de Sistemas e Industrial
2026

All models are wrong, but some are useful.

George E. P. Box

Contenido

Contenido **1**

Agradecimientos **4**

Resumen **5**

Abstract **7**

Lista de figuras **8**

Lista de tablas **9**

1 Introducción **1**

2 Marco Teórico **3**

3 Construcción de conjunto de datos para modelado **8**
3.1 Descripción de la base de datos SAML-D 8
3.2 Análisis exploratorio de datos 9
3.3 Ingeniería de características 15

4 Implementación del modelo de aprendizaje automático **21**
4.1 Entrenamiento del Modelo 21
4.2 Ajuste del Modelo de Isolation Forest 23
4.3 Selección de Umbral de Clasificación 26

5 Evaluación del modelo de aprendizaje automático **30**
5.1 Métricas de Desempeño 30
5.2 Comparación contra Benchmarks 38

6 Discusión de resultados **40**
6.1 Contribución de la ingeniería de características 40
6.2 Viabilidad operacional y comparación con sistemas basados en reglas 40
6.3 Estabilidad temporal y generalización 41
6.4 Limitaciones del estudio 42

7 Conclusiones **44**

8 Anexos **46**

8.1 Repositorio de Código 46

Referencias Bibliográficas **47**

Agradecimientos

A mi familia, por su apoyo incondicional, su paciencia y su acompañamiento constante a lo largo de este proceso.

Resumen

Modelo de aprendizaje automático para la detección de anomalías asociadas al Lavado de Activos basado en el algoritmo Isolation Forest

Resumen

Los sistemas de monitoreo transaccional basados en reglas estáticas, ampliamente utilizados por las instituciones financieras para la prevención del lavado de activos (LA), presentan limitaciones estructurales bien documentadas entre las que se incluyen la generación de volúmenes masivos de falsos positivos (con tasas que superan el 90 % de las alertas en algunos estudios de caso), poca adaptabilidad frente a la evolución de las tipologías de LA y dependencia de parametrización experta, en muchos casos subjetiva. En este contexto, el presente trabajo desarrolla un modelo de aprendizaje automático no supervisado basado en el algoritmo Isolation Forest para la detección de anomalías asociadas al lavado de activos, utilizando como base el conjunto de transacciones de depósitos en efectivo (*Cash Deposit*) proveniente de la base de datos sintética SAML-D (*Synthetic Anti-Money Laundering Dataset*), que comprende aproximadamente 9.5 millones de transacciones con múltiples canales de pago, monedas y tipologías transaccionales.

El desarrollo del modelo se estructura en tres etapas principales. En primer lugar, se construye un espacio de características de 46 variables numéricas organizadas en seis bloques temáticos (contexto geopolítico y monetario, comportamiento temporal, indicadores de estructuración (*smurfing*), estadísticas de ventana deslizante, puntuación de anomalía por cuenta (z-score) y métricas de análisis de red (grafo dirigido y ponderado)) diseñado para amplificar las diferencias comportamentales entre transacciones legítimas y sospechosas. En segundo lugar, se implementa el modelo Isolation Forest con 500 árboles de aislamiento, submuestreo de atributos al 80 % y muestreo *bootstrap*, acompañado de una evaluación sistemática de cuatro criterios de selección de umbral de clasificación. En tercer lugar, se evalúa el desempeño del modelo mediante métricas apropiadas para problemas de extremo desbalance de clases, incluyendo una validación temporal *out-of-time* que puede ser muy útil en entornos de producción.

Los resultados del modelo sobre transacciones de tipo *Cash Deposit* muestran un AUC-ROC de 0.8864 y un AUPRC de 0.2653, lo que representa una mejora de 42.5 veces sobre el clasificador aleatorio. Esta comparación contra el baseline aleatorio (cuyo AUPRC esperado es igual a la prevalencia de la clase positiva que en el caso del conjunto de datos trabajado corresponde al $\pi \approx 0{,}0062$) no es meramente teórica debido a que, en la práctica, los sistemas de monitoreo basados en reglas estáticas operan como clasificadores de umbral fijo que no aprenden la estructura discriminativa de los datos, sino que disparan alertas cuando se satisfacen condiciones predeterminadas sin capacidad de ordenar las transacciones por su grado de sospecha. Dado que estos sistemas no producen un *ranking* informado de anomalía, su capacidad para concentrar verdaderos positivos en las posiciones más altas del ordenamiento es, en términos estadísticos, comparable a la de un clasificador aleatorio que opera sobre la misma tasa de prevalencia. El lift de 42.5 veces refleja, por tanto, la ganancia concreta que aporta un modelo capaz de asignar puntuaciones de anomalía con poder discriminativo real. Con el umbral derivado del criterio F_β ($\beta = 2$), el modelo alcanza un recall del 44.27 % con una precision del 19.73 %, generando 3,152 alertas, superando ampliamente la efectividad típica de los sistemas basados en reglas, cuyas tasas de precision se documentan en el rango del 1 % al 10 %. La validación *out-of-time* (entrenamiento sobre 2022, evaluación sobre 2023) implementada con un proceso de ingeniería

de características anclado exclusivamente al período de entrenamiento para evitar fuga de información, evidencia una degradación del AUC-ROC del 5.26 % y del AUPRC del 37.5 % , manteniendo no obstante un lift de 24.9 veces sobre el baseline aleatorio. Este resultado confirma que el modelo retiene capacidad discriminativa significativa sobre datos no observados, con un nivel de degradación atribuible al cambio de patrones transaccionales entre años.

Palabras clave: detección de anomalías, lavado de activos, Isolation Forest, aprendizaje automático no supervisado, monitoreo transaccional, ingeniería de características, desbalance de clases, análisis de redes transaccionales.

Abstract

Machine Learning Model for the Detection of Anomalies Associated with Money Laundering Based on the Isolation Forest Algorithm

Rule-based transaction monitoring systems, widely deployed by financial institutions for anti-money laundering (AML) compliance, exhibit well-documented structural limitations including the generation of massive volumes of false positives (with rates exceeding 90 % of alerts in some case studies), limited adaptability to the evolution of money laundering typologies, and dependence on expert-driven parameterization that is, in many cases, subjective. In this context, the present document develops an unsupervised machine learning model based on the Isolation Forest algorithm for the detection of anomalies associated with money laundering, using as its data foundation the Cash Deposit transaction subset from the SAML-D (*Synthetic Anti-Money Laundering Dataset*), which comprises approximately 9.5 million transactions spanning multiple payment channels, currencies, and transactional typologies.

The model development is structured in three main stages. First, a feature space of 46 numerical variables is constructed, organized into six thematic blocks (geopolitical and monetary context, temporal behavior, structuring (*smurfing*) indicators, rolling window statistics, per-account anomaly scoring (z-score), and network analysis metrics (directed weighted graph)) designed to amplify behavioral differences between legitimate and suspicious transactions. Second, an Isolation Forest model is implemented with 500 isolation trees, 80 % feature subsampling, and *bootstrap* sampling, accompanied by a systematic evaluation of four classification threshold selection criteria. Third, model performance is assessed using metrics suited for extreme class imbalance problems, including an *out-of-time* temporal validation that can be highly valuable in production environments.

Results on Cash Deposit transactions yield an AUC-ROC of 0.8864 and an AUPRC of 0.2653, representing a 42.5-fold improvement over the random classifier. This comparison against the random baseline (whose expected AUPRC equals the positive class prevalence, which in the dataset under study corresponds to $\pi \approx 0{,}0062$) is not merely theoretical, since in practice, rule-based monitoring systems operate as fixed-threshold classifiers that do not learn the discriminative structure of the data but rather trigger alerts when predetermined conditions are met, without the ability to rank transactions by their degree of suspicion. Given that these systems do not produce an informed anomaly *ranking*, their ability to concentrate true positives at the top of the ordering is, in statistical terms, comparable to that of a random classifier operating at the same prevalence rate. The 42.5-fold lift therefore reflects the concrete gain provided by a model capable of assigning anomaly scores with real discriminative power. Under the F_β ($\beta = 2$) threshold criterion, the model achieves a recall of 44.27 % with a precision of 19.73 %, generating 3,152 alerts, substantially surpassing the typical effectiveness of rule-based systems, whose precision rates are documented in the 1 % to 10 % range. The *out-of-time* validation (training on 2022, evaluation on 2023) yields an AUC-ROC degradation of 5.26 % and an AUPRC degradation of 37.5 %, while maintaining a 24.9-fold lift over the random baseline. This result confirms that the model retains significant discriminatory capacity over unobserved data, with a level of degradation attributable to the change in transactional patterns between years.

Keywords: anomaly detection, money laundering, Isolation Forest, unsupervised machine learning, transaction monitoring, feature engineering, class imbalance, transactional network analysis.

Este Trabajo Final de maestría fue calificado en **septiembre** de 2026 por el(la) siguiente evaluador(a):

Felipe Restrepo Calle
Profesor Asociado - Facultad de Ingeniería – Departamento de Ingeniería de Sistemas e Industrial
Universidad Nacional de Colombia, Sede Bogotá

Lista de figuras

3-1 Distribución de la variable objetivo `Is_laundering`. Se observa un desbalance severo con un ratio de 159.3:1 entre transacciones legítimas y de lavado. 10

3-2 Análisis de la variable `Amount`: (a) histograma en escala logarítmica, (b) *violin plot* por clase, y (c) estimación de densidad por kernel (KDE). Las transacciones de lavado se concentran en rangos de monto superiores. 11

3-3 Análisis temporal por hora del día: (izq.) volumen transaccional segmentado por clase, (der.) tasa de lavado por hora. Se observa un incremento significativo de la tasa ilícita en horarios nocturnos. 12

3-4 Análisis temporal por día de la semana: (izq.) volumen transaccional, (der.) tasa de lavado. Las transacciones de fin de semana presentan una tasa de lavado del 100 %. 12

3-5 Evolución mensual del volumen transaccional (barras, eje izquierdo) y la tasa de lavado (línea, eje derecho) para transacciones de tipo *Cash Deposit*. 13

3-6 Caracterización de las tipologías de lavado: (izq.) frecuencia por tipología, (der.) monto promedio por tipología. El *Smurfing* es más frecuente pero involucra montos menores que *Deposit-Send*. . . . 13

3-7 Las 15 cuentas emisoras con mayor volumen de transacciones ilícitas. La anotación *n/n txns* indica que la totalidad de transacciones de cada cuenta corresponden a lavado. 14

5-1 Distribución de scores de anomalía. 31

5-2 Curva ROC del modelo *Isolation Forest* sobre transacciones *Cash Deposit*. La marca naranja señala el punto óptimo según el índice de Youden. 32

5-3 Curva Precision-Recall.. 33

5-4 Evolución de la métrica F-β ($\beta = 2$) en función del umbral de clasificación. La línea naranja marca el umbral seleccionado $\delta^* = 0{,}5923$ que maximiza la métrica.. 34

5-5 *Precision* y *recall* como función del umbral de clasificación. La línea naranja indica el umbral seleccionado por el criterio F-β. 35

5-6 Matriz de confusión. 36

Lista de tablas

2-1 Clasificación general de enfoques de detección de anomalías aplicables a AML, basada en *Chandola et al.* [2009] y *Chen et al.* [2018]. 4
2-2 Comparación de algoritmos de detección de anomalías 6

3-1 Estadísticas descriptivas de la variable `Amount` en transacciones *Cash Deposit*. 10
3-2 Estadísticas del monto transaccional (`Amount`) segmentadas por clase. 11
3-3 Pruebas de asociación con la variable objetivo `Is_laundering`. 14

4-1 Hiperparámetros del modelo Isolation Forest y su justificación. 25
4-2 Comparativa de criterios de selección de umbral. Métricas calculadas sobre el conjunto de datos de evaluación. AUC-ROC = 0.8864; AUPRC = 0.2653. 28

5-1 Métricas globales de desempeño — IForest Cash Deposit 30
5-2 Comparación de criterios de selección de umbral. 33
5-3 Matriz de confusión — umbral F-β (β=2): 0.5923 36
5-4 Resultados de la validación temporal *out-of-time* 37
5-5 Comparación contra benchmarks no supervisados sobre el mismo espacio de características . . 38

1 Introducción

El lavado de activos (LA) y la financiación del terrorismo (FT) constituyen fenómenos criminales de alcance global que erosionan la estabilidad económica, favorecen la corrupción y deterioran la confianza en el sistema financiero [*Teichmann*. 2019]. De acuerdo con estimaciones de la Oficina de las Naciones Unidas contra la Droga y el Delito (UNODC), entre el 2 % y el 5 % del PIB mundial podría estar vinculado a flujos ilícitos asociados al lavado de dinero, lo que implica montos de billones de dólares que circulan anualmente a través de canales formales e informales de la economía mundial [*United Nations Office on Drugs and Crime*. 2011].

En este contexto, los sistemas de monitoreo transaccional implementados por las instituciones financieras se han apoyado históricamente en motores basados en reglas, que activan alertas cuando ciertas condiciones predefinidas, tales como umbrales de monto, frecuencias inusuales o combinaciones específicas de variables, se cumplen [*Chen et al.*. 2018]. Sin embargo, la literatura reciente ha documentado de manera consistente que estos enfoques presentan limitaciones estructurales entre los que se incluyen la generación de volúmenes masivos de falsos positivos, poca adaptabilidad frente a la evolución de las tipologías de LA y fuerte dependencia del conocimiento experto para su parametrización [*Bakry et al.*. 2024; *Oztas et al.*. 2024]. En algunos estudios de caso, la proporción de alertas correspondientes a falsos positivos en sistemas basados en reglas alcanza niveles superiores al 90 %, lo que sobrecarga a los equipos de cumplimiento, incrementa costos operativos e introduce el riesgo de que eventos verdaderamente riesgosos pasen inadvertidos [*Bakry et al.*. 2024; *Oztas et al.*. 2024].

A estas dificultades se suma la escasez de datos etiquetados de calidad para entrenar modelos supervisados de aprendizaje automático. Los casos confirmados de lavado de activos suelen ser poco frecuentes, están altamente protegidos por restricciones legales y de confidencialidad y no se comparten de manera abierta entre instituciones o jurisdicciones [*Chen et al.*. 2018; *Ngai et al.*. 2011]. Como consecuencia, diversos trabajos han señalado la necesidad de explorar enfoques no supervisados y técnicas de detección de anomalías que permitan identificar patrones inusuales sin requerir etiquetas explícitas de ‘‘transacción sospechosa’’ [*Chandola et al.*. 2009; *Domingues et al.*. 2018].

En este escenario, los modelos de aprendizaje automático no supervisado, y en particular los algoritmos de detección de anomalías, emergen como una alternativa promisoria para complementar o reconfigurar los esquemas tradicionales de monitoreo transaccional. La literatura muestra resultados alentadores del uso de algoritmos como *Isolation Forest*, *Local Outlier Factor*, métodos basados en *clustering* y enfoques de representación profunda para el descubrimiento de comportamientos atípicos en dominios como detección de fraudes con tarjetas de crédito, intrusiones en redes y otras formas de abuso financiero [*Chandola et al.*. 2009; *Ghevariya et al.*. 2021; *Sirisha et al.*. 2021]. En particular, *Isolation Forest* ha demostrado combinar buena capacidad de detección con eficiencia computacional en conjuntos de datos de alta dimensionalidad y gran volumen [*Liu et al.*. 2008; *Domingues et al.*. 2018].

En paralelo, han surgido conjuntos de datos sintéticos de alta complejidad diseñados específicamente para investigación en monitoreo transaccional de AML, que buscan superar las restricciones de acceso a datos reales. Entre ellos se encuentra SAML-D (*Synthetic Anti-Money Laundering Dataset*), un conjunto de datos sintético que modela más de nueve millones de transacciones, incluyendo múltiples tipologías normales y sospechosas, distintas monedas, ubicaciones geográficas y canales de pago [*Oztas et al.*. 2023]. Este tipo de conjuntos de datos proporciona un entorno controlado y reproducible para entrenar y evaluar modelos de detección de anomalías, manteniendo al mismo tiempo un alto grado de realismo en las estructuras de las transacciones y en los patrones de comportamiento [*Oztas et al.*. 2023].

En este contexto, el presente trabajo tiene como propósito desarrollar un modelo de aprendizaje automático no supervisado, basado en el algoritmo *Isolation Forest*, para la detección de anomalías asociadas al lavado de activos utilizando como base el conjunto de datos SAML-D. El objetivo general es desarrollar un modelo de aprendizaje automático no supervisado para la detección de anomalías asociadas al lavado de activos basado en el algoritmo *Isolation Forest*. A partir de este propósito, se plantean como objetivos específicos: (i) construir un conjunto de datos de modelado partiendo de la base transaccional SAML-D, incorporando transformaciones y variables derivadas relevantes desde la perspectiva de comportamiento transaccional; (ii) implementar el modelo de aprendizaje automático para la detección de anomalías empleando *Isolation Forest*; y (iii) evaluar el desempeño del modelo utilizando métricas de evaluación de desempeño pertinentes para problemas desbalanceados y orientados a detección de anomalías, tales como precisión, *recall*, F1-*score*, curvas ROC/PR y tasas de falsos positivos [*Chandola et al.*. 2009; *Sirisha et al.*. 2021].

Finalmente, la estructura del trabajo se organiza de la siguiente manera. En el *marco teórico* se presentan los fundamentos conceptuales del lavado de activos, los sistemas tradicionales de monitoreo transaccional, los enfoques de aprendizaje automático aplicados a AML y los principios del algoritmo *Isolation Forest*. En el capítulo 3 se describe la base de datos a utilizar incluyendo un análisis exploratorio de datos y el proceso de construcción del conjunto de datos de modelado a través de ingeniería de características. El capítulo 4 muestra la configuración del modelo y su implementación. En el capítulo 5 se describen las métricas de evaluación y, finalmente , se exponen y analizan los resultados obtenidos, para luego discutir sus implicaciones prácticas y sus limitaciones, así como posibles líneas de trabajo futuro orientadas al fortalecimiento de los sistemas de monitoreo transaccional en instituciones financieras.

2 Marco Teórico

El presente capítulo establece los fundamentos conceptuales sobre los que se construye el modelo propuesto. Se inicia con una caracterización del fenómeno del lavado de activos y del papel que desempeña el monitoreo transaccional en su prevención, para luego analizar las limitaciones estructurales de los sistemas basados en reglas que predominan en la industria financiera. A continuación, se revisa la literatura sobre la aplicación de técnicas de aprendizaje automático a la detección de fraude y lavado de activos, con énfasis en los enfoques no supervisados que resultan particularmente atractivos ante la escasez de datos etiquetados de calidad en este dominio. Posteriormente, se introducen los conceptos fundamentales de la detección de anomalías y se profundiza en los principios del algoritmo *Isolation Forest*, justificando su selección frente a otros métodos no supervisados comparables. El capítulo cierra con una discusión sobre las métricas de evaluación apropiadas para problemas de extremo desbalance de clases, las cuales serán empleadas en la fase de evaluación del modelo.

Lavado de activos y monitoreo transaccional

El lavado de activos puede definirse, en términos generales, como el proceso mediante el cual se buscan legitimar recursos de origen ilícito mediante su inserción en el sistema financiero formal, con el fin de ocultar su procedencia y apariencia original [*Teichmann*. 2019]. Diversos autores coinciden en que se trata de un fenómeno dinámico, que evoluciona en función de cambios regulatorios, innovaciones tecnológicas y nuevas oportunidades en los mercados financieros y no financieros [*Teichmann*. 2019; *Chen et al.*. 2018].

Dentro de los mecanismos de prevención y detección de LA/FT, el monitoreo transaccional ocupa un lugar central. Este proceso consiste en la revisión sistemática de las transacciones realizadas por clientes y contrapartes, con el fin de identificar patrones inusuales o sospechosos que puedan asociarse a tipologías de lavado, tales como estructuración, *smurfing*, uso de cuentas puente, transacciones transfronterizas sin justificación económica, uso intensivo de efectivo u operaciones circulares, entre otras [*Chen et al.*. 2018; *Oztas et al.*. 2024]. Los marcos regulatorios de múltiples jurisdicciones exigen a las entidades financieras contar con sistemas de monitoreo transaccional robustos, capaces de generar alertas oportunas para su análisis por parte de equipos especializados de cumplimiento.

Sistemas basados en reglas y sus limitaciones

Históricamente, el monitoreo transaccional se ha instrumentado mediante sistemas de reglas estáticas que disparan alertas cuando se cumplen condiciones predeterminadas, por ejemplo, cuando una transacción supera cierto umbral monetario, cuando la frecuencia de movimientos excede parámetros establecidos o cuando se detectan combinaciones de países, monedas y canales considerados de riesgo [*Chen et al.*. 2018]. Este enfoque tiene como ventaja su transparencia y facilidad de explicación debido a que las instituciones pueden documentar con claridad qué condiciones generan una alerta y cómo se relacionan con riesgos particulares.

No obstante, la literatura ha documentado múltiples desventajas de estos esquemas. En primer lugar, la rigidez de las reglas hace que el sistema sea poco flexible ante la aparición de nuevas tipologías de LA o la adaptación de los delincuentes a los umbrales establecidos [*Bakry et al.*. 2024; *Oztas et al.*. 2024]. En segundo lugar, al no considerar la estructura completa de los datos ni el contexto relacional entre transacciones y

clientes, las reglas tienden a producir grandes volúmenes de falsos positivos, saturando la capacidad operativa de los analistas e incrementando los costos de investigación [*Bakry et al.*. 2024]. Finalmente, la puesta a punto de estos sistemas depende en gran medida del juicio experto, lo que introduce subjetividad y dificulta su calibración óptima en entornos de datos complejos.

Aprendizaje automático en la detección de lavado de activos

En respuesta a las limitaciones de los sistemas basados en reglas, ha surgido una amplia literatura que explora el uso de técnicas de minería de datos y aprendizaje automático para la detección de fraudes financieros y lavado de activos. Revisiones como las de *Ngai et al.* [2011], *Phua et al.* [2010] y *Chen et al.* [2018] muestran una evolución desde modelos estadísticos clásicos hacia enfoques de *machine learning* más sofisticados, incluyendo métodos supervisados, no supervisados y semi-supervisados.

En el ámbito supervisado, se han utilizado algoritmos como árboles de decisión, bosques aleatorios, máquinas de soporte vectorial, redes neuronales y enfoques de ensamblado, especialmente en problemas de fraude con tarjetas de crédito [*Bahnsen et al.*. 2016; *Dal Pozzolo et al.*. 2014; *Jurgovsky et al.*. 2018]. Estos modelos requieren grandes volúmenes de ejemplos etiquetados de transacciones normales y fraudulentas, lo cual es factible en ciertos dominios, pero resulta problemático en AML debido a la baja incidencia de casos confirmados y a la sensibilidad de la información [*Chen et al.*. 2018].

Frente a estas restricciones, se ha incrementado el interés en enfoques no supervisados y semi-supervisados que buscan modelar el comportamiento ‘‘normal’’ de los clientes y detectar desviaciones significativas sin requerir etiquetas exhaustivas. Este grupo incluye métodos de *clustering*, modelos basados en densidad, técnicas de detección de anomalías y arquitecturas profundas como *autoencoders* o redes recurrentes entrenadas para reconstruir series temporales y resaltar patrones atípicos [*Chandola et al.*. 2009; *Fiore et al.*. 2019; *Kieu et al.*. 2019; *Malhotra et al.*. 2015]. En el campo de AML, *Chen et al.* [2018] destacan que la escasez de datos etiquetados hace especialmente atractivos los algoritmos de detección de anomalías como alternativa para fortalecer los sistemas de monitoreo transaccional.

Tabla 2-1: Clasificación general de enfoques de detección de anomalías aplicables a AML, basada en *Chandola et al.* [2009] y *Chen et al.* [2018].

Familia de métodos	**Idea principal**	**Ejemplos típicos**
Basados en distancia	Puntos lejanos a sus vecinos son anómalos	k-NN outlier, distancias de Mahalanobis [*Chandola et al.*. 2009]
Basados en densidad	Las anomalías tienen densidad local mucho menor que sus vecinos	Local Outlier Factor (LOF) [*Breunig et al.*. 2000a]
Basados en *clustering*	Puntos muy distantes de cualquier clúster o en clústeres pequeños son *outliers*	K-means + distancia al centroide [*Sun et al.*. 2020]
Basados en reconstrucción	Errores de reconstrucción altos indican anomalías	Autoencoders, LSTM autoencoders [*Malhotra et al.*. 2015; *Kieu et al.*. 2019]
Basados en aislamiento	Las anomalías se aíslan rápidamente mediante particiones aleatorias	Isolation Forest [*Liu et al.*. 2008; *Domingues et al.*. 2018]

Detección de anomalías: conceptos fundamentales

La detección de anomalías se refiere a la identificación de observaciones que se desvían significativamente del patrón general presente en un conjunto de datos, de tal forma que despiertan sospecha de haber sido generadas por mecanismos distintos [*Chandola et al.*. 2009]. En el contexto de AML, dichas anomalías pueden corresponder a transacciones inusuales, secuencias de movimientos atípicas, patrones de relacionamiento poco frecuentes o configuraciones de variables que no son coherentes con el comportamiento histórico del cliente.

Chandola et al. [2009] distinguen, entre otros, tres escenarios de interés: (i) detección de anomalías puntual, en la que se analizan observaciones independientes; (ii) detección de anomalías contextual, donde la rareza se define en relación con variables de contexto (por ejemplo, país, canal, periodo del día); y (iii) detección de anomalías colectiva, que se enfoca en grupos de observaciones que, en conjunto, resultan atípicas, aunque individualmente no lo parezcan. En AML, las tres perspectivas son relevantes, ya que ciertos esquemas de lavado se manifiestan a través de series de transacciones coordinadas en el tiempo o entre múltiples cuentas, en lugar de en una única operación aislada [*Chen et al.*. 2018].

Algoritmo Isolation Forest

Isolation Forest (IF) es un algoritmo de detección de anomalías no supervisado que se basa en la idea de que las observaciones anómalas son ‘‘más fáciles de aislar’’ que las normales mediante particiones aleatorias del espacio de atributos [*Liu et al.*. 2008]. El método construye múltiples árboles de aislamiento (*iTrees*) a partir de submuestras aleatorias del conjunto de datos, que, en cada nodo, selecciona aleatoriamente una característica y un punto de corte, particionando recursivamente los datos hasta que cada observación quede aislada. La longitud media del camino necesario para aislar un punto se utiliza como indicador en el cual las anomalías tienden a requerir menos particiones, resultando en caminos más cortos y, por tanto, en mayores puntajes de anomalía.

Desde el punto de vista computacional, *Isolation Forest* presenta una complejidad aproximadamente lineal en el número de observaciones siempre que el tamaño de submuestra por árbol y el número de árboles se mantengan fijos, lo que lo hace especialmente adecuado para conjuntos de datos masivos como los que se encuentran en monitoreo transaccional [*Liu et al.*. 2008]. Estudios comparativos han mostrado que IF es competitivo, e incluso superior, frente a otros métodos no supervisados en tareas de detección de fraudes y anomalías en alta dimensión, tanto en términos de capacidad de detección como de tiempo de cómputo [*Domingues et al.*. 2018; *Ghevariya et al.*. 2021; *Sirisha et al.*. 2021].

Además de su versión estándar, se han propuesto extensiones como *Extended Isolation Forest*, que mejora la capacidad de modelar fronteras de decisión más complejas mediante hiperplanos oblicuos en lugar de particiones alineadas a los ejes, aumentando la flexibilidad del modelo en dominios de alta dimensionalidad [*Hariri et al.*. 2019].

Para efectos de implementación y análisis, resulta útil sintetizar las principales características de *Isolation Forest* y compararlas con otros métodos representativos. La siguiente tabla resume algunos aspectos clave de estos algoritmos no supervisados:

Tabla 2-2: Comparación de algoritmos de detección de anomalías

Algoritmo	**Supuestos clave**	**Complejidad**	**Ventajas**	**Desventajas**	**Año / Referencia**
Isolation Forest	Anomalías definidas como aislamientos rápidos mediante particiones aleatorias; no requiere una distribución previa.	$\mathcal{O}(n)$	No supervisado. Escalable. Robusto al ruido y a alta dimensionalidad.	Puede pasar por alto anomalías locales. Variabilidad aleatoria. Explicabilidad limitada.	Liu, Ting y Zhou (2008). *Isolation Forest*. IEEE ICDM.
Local Outlier Factor (LOF)	Un punto es considerado outlier si su densidad local es anormalmente baja respecto a sus vecinos.	$\mathcal{O}(n^2)$	Detecta anomalías locales en densidades variables.	No escala a grandes volúmenes de datos. Mal rendimiento en alta dimensión. Sensible al parámetro k.	Breunig et al. (2000). *LOF*. SIGMOD.
K-means	Los datos pueden agruparse en K clusters esféricos; los outliers son puntos distantes de cualquier centroide.	$\mathcal{O}(n \cdot K \cdot I \cdot d)$	Rápido y simple. Segmenta perfiles de comportamiento normal.	No robusto a outliers (afecta centroides). Ignora anomalías locales. Sensible a la inicialización.	Lloyd (1957/1982). *Least Squares Quantization*. IEEE TIT.

Otros enfoques no supervisados relevantes para AML

Aunque la presente tesis se centra en *Isolation Forest*, es importante situarlo dentro del ecosistema de enfoques no supervisados explorados en AML. Los métodos basados en densidad, como LOF, han sido utilizados para detectar puntos cuya densidad local es significativamente inferior a la de sus vecinos, permitiendo descubrir anomalías contextuales en regiones de distinta densidad [*Breunig et al.*. 2000a]. Sin embargo, su costo computacional y su sensibilidad a la dimensión limitan su aplicabilidad directa en grandes volúmenes de transacciones financieras [*Chandola et al.*. 2009].

Por su parte, los métodos de *clustering*, como K-means, se han utilizado para segmentar clientes o comportamientos transaccionales y posteriormente identificar como sospechosos aquellos puntos alejados de los centroides o pertenecientes a clústeres pequeños, aunque su capacidad para detectar anomalías locales es reducida y la presencia de *outliers* puede distorsionar la estructura de los clústeres [*Sun et al.*. 2020]. Más recientemente, se han propuesto arquitecturas profundas (por ejemplo, *autoencoders* y redes recurrentes) para modelar secuencias de transacciones y detectar patrones anómalos a través de errores de reconstrucción o desviaciones en la dinámica temporal [*Fiore et al.*. 2019; *Malhotra et al.*. 2015; *Kieu et al.*. 2019]. Estos enfoques ofrecen un alto potencial, pero también requieren volúmenes de datos y capacidades computacionales

significativas.

Métricas de evaluación en problemas de detección de anomalías para AML

La evaluación de modelos de detección de anomalías en entornos de AML plantea retos específicos debido al fuerte desbalance entre clases y al alto costo relativo de los errores de clasificación. Métricas globales como la exactitud (*accuracy*) pueden resultar engañosas, ya que un modelo que clasifique casi todas las transacciones como normales puede alcanzar valores muy altos de exactitud, a pesar de no detectar la mayoría de los eventos ilícitos [*Chandola et al.*. 2009; *Ghevariya et al.*. 2021].

En este tipo de problemas, suele ponerse énfasis en métricas como: (i) el *recall* o tasa de verdaderos positivos, que refleja la proporción de transacciones sospechosas correctamente identificadas; (ii) la precisión (*precision*), que mide la fracción de alertas generadas que efectivamente corresponden a eventos sospechosos; (iii) el F1-*score*, que equilibra precisión y *recall*; y (iv) métricas derivadas de curvas ROC y PR, como el área bajo la curva (AUC), que permiten comparar modelos a lo largo de distintos umbrales de decisión [*Sirisha et al.*. 2021]. En la literatura sobre fraude e intrusión se ha observado que modelos como *Isolation Forest* pueden alcanzar altos niveles de *recall*, aunque a costa de mayores tasas de falsos positivos, lo que obliga a una calibración cuidadosa acorde con la capacidad operativa de las áreas de cumplimiento [*Ghevariya et al.*. 2021; *Sirisha et al.*. 2021].

Dado el carácter operativo de los sistemas de monitoreo transaccional, también resultan relevantes métricas como el volumen de alertas diarias generado, la tasa de falsos positivos por analista o el porcentaje de alertas escaladas que terminan en reporte a las autoridades, aunque estas últimas dependan de factores organizacionales adicionales [*Bakry et al.*. 2024; *Oztas et al.*. 2024]. La presente tesis considerará un conjunto de métricas orientadas a capturar tanto la capacidad de detección de anomalías del modelo *Isolation Forest* como su viabilidad práctica en términos de volumen de alertas y precisión, en línea con las recomendaciones de la literatura especializada en materia de AML.

3 Construcción de conjunto de datos para modelado

Este capítulo describe el proceso mediante el cual los datos transaccionales en bruto son transformados en un conjunto de datos apto para el entrenamiento del modelo *Isolation Forest*. La construcción se desarrolla en tres etapas. En primer lugar, se presenta el conjunto de datos SAML-D y se justifica la decisión metodológica de restringir el análisis al subconjunto de transacciones de tipo *Cash Deposit*, escogencia que se fundamenta tanto en consideraciones teóricas del marco GAFI/FATF como en evidencia regulatoria y empírica que posiciona a los depósitos en efectivo como la tipología de mayor riesgo inherente en materia de lavado de activos. En segundo lugar, se desarrolla un análisis exploratorio orientado a caracterizar las propiedades estadísticas del conjunto de datos, identificar patrones de comportamiento diferenciados entre transacciones legítimas y sospechosas, y sustentar las decisiones de diseño del modelo. Finalmente, se describe el pipeline de ingeniería de características que transforma las transacciones individuales en un espacio numérico de 46 variables organizadas en seis bloques temáticos, diseñado para amplificar las señales discriminativas que el algoritmo Isolation Forest podrá explotar durante el entrenamiento.

3.1 Descripción de la base de datos SAML-D

La falta de conjuntos de datos públicos y etiquetados para AML ha sido señalada reiteradamente como una de las principales barreras para la investigación y validación de modelos de aprendizaje automático en este dominio [*Chen et al.*. 2018; *Oztas et al.*. 2023]. Para mitigar esta limitación, se han propuesto generadores de datos sintéticos que permiten simular transacciones con alto grado de realismo a partir de tipologías documentadas, conocimiento experto y estructuras de red que capturan relaciones entre cuentas y entidades.

SAML-D (*Synthetic Anti-Money Laundering Dataset*), el conjunto de datos que será empleado para el presente trabajo final de maestría, es un ejemplo reciente y relevante de este tipo de recursos. Desarrollado en el marco de la 2023 IEEE International Conference on e-Business Engineering, SAML-D contiene alrededor de 9,5 millones de transacciones, de las cuales una fracción muy pequeña corresponde a operaciones etiquetadas como sospechosas, reflejando el fuerte desbalance típico de escenarios reales de AML [*Oztas et al.*. 2023]. El conjunto de datos incorpora diferentes canales de pago (tarjetas de crédito y débito, transferencias ACH, cheques, transacciones transfronterizas, entre otros), múltiples monedas, ubicaciones geográficas y una clasificación en 28 tipologías transaccionales (11 normales y 17 sospechosas), construidas a partir de literatura académica, entrevistas con expertos y análisis de conjuntos de datos existentes [*Oztas et al.*. 2023].

Para efectos de la presente tesis, SAML-D ofrece un entorno controlado pero realista para el entrenamiento y evaluación de modelos de detección de anomalías basados en *Isolation Forest*. Al tratarse de datos sintéticos, se facilita el acceso y la replicabilidad de los experimentos, al tiempo que se preserva la complejidad estructural de las transacciones y sus patrones de relacionamiento [*Oztas et al.*. 2023].

Selección del subconjunto de datos para la elaboración del modelo

Del universo total de transacciones contenidas en la base de datos, el modelo desarrollado en el marco de este trabajo se ejecuta exclusivamente sobre el subconjunto de registros cuyo campo `Payment_Type` es igual a `Cash Deposit`. Esta decisión de alcance obedece a consideraciones tanto teóricas como regulatorias que

posicionan a los depósitos en efectivo como la tipología transaccional de mayor riesgo inherente en materia de lavado de activos.

Desde el marco conceptual del GAFI/FATF, el lavado de activos se estructura en tres etapas: colocación (*placement*), estratificación (*layering*) e integración (*integration*) *Financial Action Task Force* [2018]. La etapa de colocación, considerada la fase de mayor vulnerabilidad para el criminal, dado que implica la introducción de grandes volúmenes de dinero ilícito en el sistema financiero formal, se materializa predominantemente a través de depósitos en efectivo en cuentas bancarias *Financial Action Task Force* [2024]; *Sanctions.io* [2025]. Técnicas como el *structuring* o *smurfing*, que consisten en fraccionar sumas elevadas en montos por debajo de los umbrales de reporte obligatorio para realizar múltiples depósitos en efectivo, son reconocidas por el FATF y por organismos como FinCEN como métodos primarios de colocación *Financial Action Task Force* [2024]; *FFIEC* [2023b].

El manual de examen BSA/AML del FFIEC identifica explícitamente a los negocios intensivos en efectivo (*cash-intensive businesses*) como entidades de alto riesgo, señalando que los depósitos en efectivo constituyen el principal vector mediante el cual los fondos ilícitos ingresan al sistema bancario *FFIEC* [2023a]. Asimismo, la Evaluación Nacional de Riesgo de Lavado de Activos de los Estados Unidos (NMLRA 2024) subraya que las organizaciones criminales transnacionales continúan utilizando el efectivo como medio preferente para lavar fondos ilícitos, dada su anonimidad, estabilidad y amplia aceptación *U.S. Department of the Treasury* [2024].

En el contexto colombiano, la Unidad de Información y Análisis Financiero (UIAF) ha identificado que las operaciones en efectivo representan uno de los canales más frecuentes de lavado de activos, con estimaciones que sitúan el monto lavado anualmente entre el 2 % y el 3 % del PIB *Sumsub* [2023]. El marco regulatorio SARLAFT, aplicable a las instituciones financieras supervisadas por la Superintendencia Financiera de Colombia, establece la obligación de aplicar controles reforzados y monitoreo continuo sobre las transacciones en efectivo, reconociendo su naturaleza inherentemente riesgosa *Superintendencia Financiera de Colombia* [2016].

Por lo anterior, la focalización del modelo en transacciones de tipo `Cash Deposit` permite concentrar la capacidad analítica y computacional en el segmento transaccional donde la probabilidad *a priori* de actividad sospechosa es significativamente mayor, optimizando así la relación señal-ruido del sistema de detección y alineándose con las mejores prácticas internacionales en monitoreo AML basado en riesgo.

3.2 Análisis exploratorio de datos

En esta sección se presentan los hallazgos más relevantes del análisis realizado sobre las transacciones de tipo *Cash Deposit*, las cuales fueron filtradas del conjunto de datos completo para su estudio en profundidad.

Descripción del conjunto de datos

El subconjunto de datos analizado comprende **225,206 transacciones** de tipo *Cash Deposit*, registradas entre el 7 de octubre de 2022 y el 23 de agosto de 2023. El dataset cuenta con 13 variables que capturan información temporal (`Date`, `Time`), financiera (`Amount`, `Payment_currency`, `Received_currency`), geográfica (`Sender_bank_location`, `Receiver_bank_location`), identificadores de cuenta (`Sender_account`, `Receiver_account`) y la variable objetivo binaria `Is_laundering` utilizada para efectos de investigación.

La Tabla **3-1** presenta las estadísticas descriptivas de la variable `Amount`, cuya distribución exhibe una asimetría positiva pronunciada (*skewness* = 1.97) y una curtosis elevada (22.29), indicando la presencia de colas pesadas y valores extremos. El coeficiente de variación de 0.74 refleja una dispersión considerable respecto a la media.

Distribución de la variable objetivo

La variable objetivo `Is_laundering` presenta un desbalance de clases severo al punto en que, de las 225,206 transacciones, únicamente **1,405** (0.62 %) corresponden a operaciones de lavado de activos, mientras que las restantes **223,801** (99.38 %) son legítimas. Esto configura un ratio de desbalance aproximado de

Tabla 3-1: Estadísticas descriptivas de la variable `Amount` en transacciones *Cash Deposit*.

Estadístico	Valor
Conteo	225,206
Media	2,157.18
Desv. estándar	1,597.42
Mínimo	50.19
Q1 (25 %)	887.99
Mediana (50 %)	1,766.90
Q3 (75 %)	3,157.45
Máximo	43,909.92
Coef. variación	0.7405
IQR	2,269.46
Asimetría	1.9708
Curtosis	22.2926

159.3:1, lo cual tiene implicaciones directas sobre la selección de métricas de evaluación del modelo, en donde métricas como el *F1-score*, *Precision-Recall AUC* y el coeficiente de Matthews resultan más informativas que la exactitud (*accuracy*), así como sobre las estrategias de muestreo a emplear durante el entrenamiento.

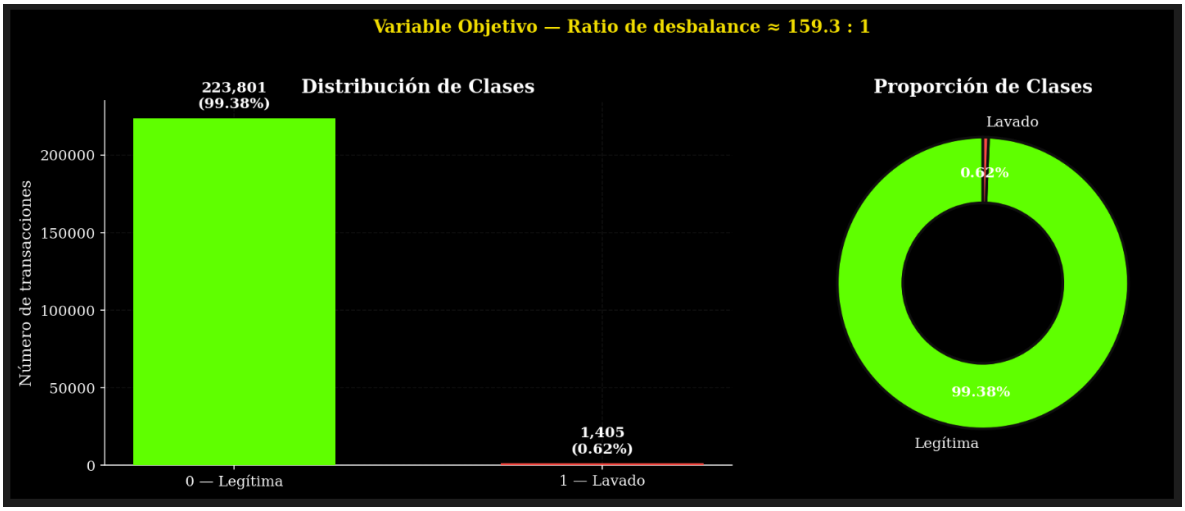


Figura 3-1: Distribución de la variable objetivo `Is_laundering`. Se observa un desbalance severo con un ratio de 159.3:1 entre transacciones legítimas y de lavado.

Análisis de la variable Amount

El monto transaccional constituye una de las variables con mayor poder discriminativo para la detección de operaciones sospechosas. La Tabla **3-2** evidencia una diferencia sustancial entre clases. Las transacciones ilícitas presentan un monto promedio de **4,949.03**, lo cual representa un incremento del 131.3 % respecto al promedio de las transacciones legítimas (2,139.65). Además, el monto mínimo observado en transacciones de lavado (1,007.96) es considerablemente superior al mínimo global (50.19), lo que sugiere que las operaciones ilícitas por *Cash Deposit* tienden a evitar montos muy bajos.

La Figura **3-2** muestra tres perspectivas complementarias de la distribución del monto. El histograma en escala logarítmica revela una concentración en el rango de 10^2 a 10^4. El *violin plot* comparativo permite apreciar que la distribución de la clase de lavado presenta una cola derecha más extendida y una mediana desplazada hacia valores superiores. Por su parte, la estimación de densidad por kernel (KDE) muestra que las transacciones de lavado presentan una densidad más alta en el rango de montos entre $10^{3,3}$ y $10^{4,6}$

Tabla 3-2: Estadísticas del monto transaccional (`Amount`) segmentadas por clase.

Estadístico	Legítima (0)	Lavado (1)
Conteo	223,801	1,405
Media	2,139.65	4,949.03
Desv. estándar	1,521.71	5,687.22
Mínimo	50.19	1,007.96
Q1 (25 %)	882.83	2,143.36
Mediana (50 %)	1,758.08	3,035.19
Q3 (75 %)	3,146.75	4,802.39
Máximo	5,999.97	43,909.92

aproximadamente, lo cual resulta consistente con patrones de estructuración (*smurfing*) y operaciones de alto valor.

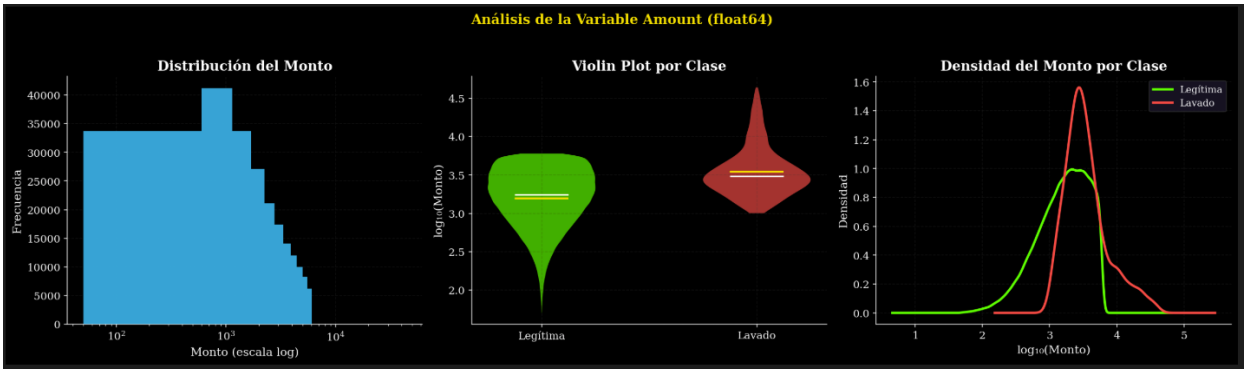


Figura 3-2: Análisis de la variable `Amount`: (a) histograma en escala logarítmica, (b) *violin plot* por clase, y (c) estimación de densidad por kernel (KDE). Las transacciones de lavado se concentran en rangos de monto superiores.

Análisis temporal

El análisis de la distribución horaria (Figura **3-3**) revela un hallazgo particularmente relevante que indica que la tasa de lavado no es uniforme a lo largo del día, sino que exhibe un incremento notable en las horas de la noche y la madrugada, alcanzando picos cercanos al 100 % en las horas 22 y 23. Este patrón temporal es consistente con el comportamiento esperado de operaciones ilícitas, las cuales tienden a realizarse fuera del horario habitual de actividad bancaria para reducir la exposición a controles y supervisión.

En cuanto a la distribución por día de la semana, la tasa de lavado se mantiene relativamente estable entre lunes y viernes con valores cercanos a la tasa global (0.62 %), pero se eleva drásticamente durante el fin de semana, alcanzando un 100 % los sábados y domingos. Este comportamiento sugiere que la totalidad de las transacciones de tipo *Cash Deposit* registradas en fines de semana corresponden a operaciones ilícitas, lo cual configura una señal temporal de alto valor discriminativo para el modelo.

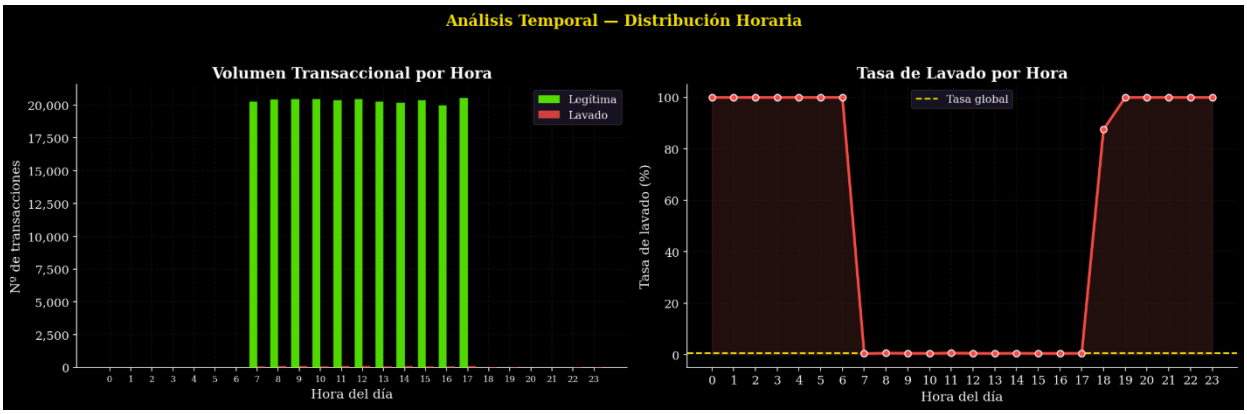


Figura 3-3: Análisis temporal por hora del día: (izq.) volumen transaccional segmentado por clase, (der.) tasa de lavado por hora. Se observa un incremento significativo de la tasa ilícita en horarios nocturnos.

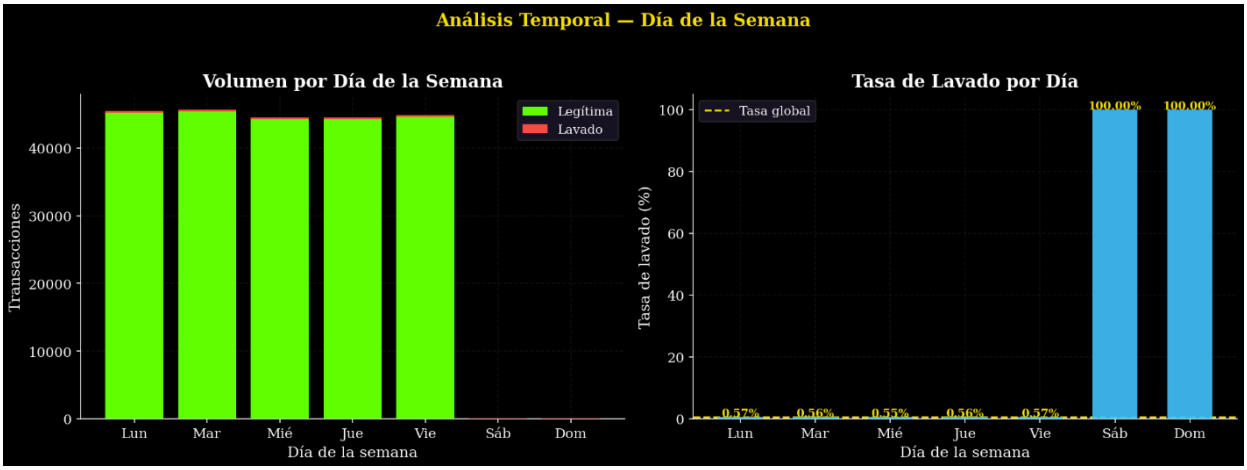


Figura 3-4: Análisis temporal por día de la semana: (izq.) volumen transaccional, (der.) tasa de lavado. Las transacciones de fin de semana presentan una tasa de lavado del 100 %.

La Figura **3-5** presenta la evolución mensual del volumen transaccional y la tasa de lavado durante el periodo de observación. Se observa que el volumen de transacciones se estabiliza a partir de enero de 2023 en torno a las 20,000 operaciones mensuales, tras un descenso pronunciado en diciembre de 2022. La tasa de lavado, por su parte, exhibe fluctuaciones entre 0.45 % y 0.80 %, sin una tendencia monotónica clara, aunque alcanza sus valores más elevados en enero de 2023 y agosto de 2023. Cabe destacar que diciembre de 2022 presenta simultáneamente el menor volumen y la menor tasa de lavado, lo cual podría atribuirse a un registro parcial del mes o a estacionalidad en la actividad transaccional.

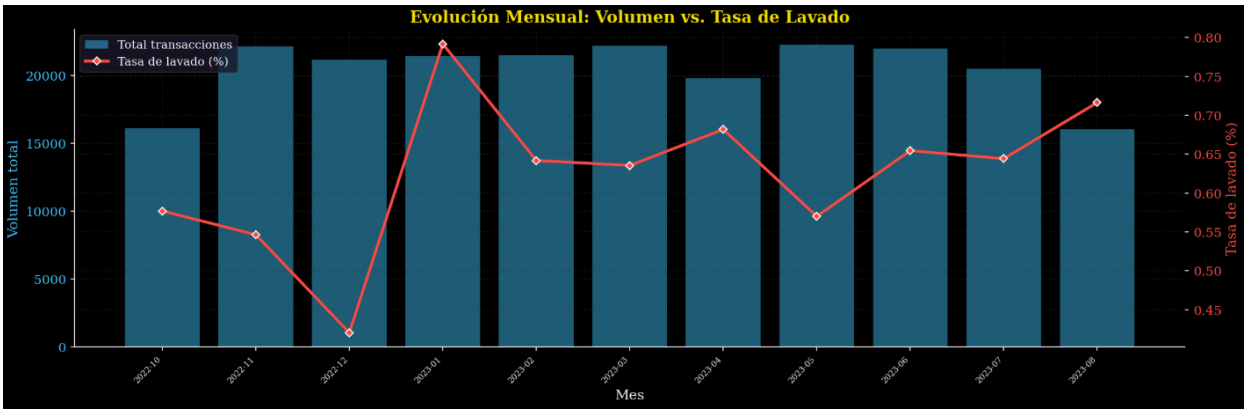


Figura 3-5: Evolución mensual del volumen transaccional (barras, eje izquierdo) y la tasa de lavado (línea, eje derecho) para transacciones de tipo *Cash Deposit*.

Tipologías de lavado

Entre las 1,405 transacciones identificadas como lavado, se distinguen dos tipologías: *Smurfing*, que representa la mayoría con 932 casos (66.3 %), y *Deposit-Send*, con 473 casos (33.7 %). Estas tipologías difieren no solo en frecuencia sino también en el monto promedio involucrado: las operaciones de tipo *Deposit-Send* presentan un monto promedio significativamente mayor que las de *Smurfing*, lo cual es consistente con la naturaleza de cada esquema. Mientras que el *smurfing* se caracteriza por la fragmentación de montos grandes en múltiples transacciones de menor valor para evadir umbrales de reporte, el esquema *Deposit-Send* involucra depósitos de mayor cuantía seguidos de transferencias inmediatas.

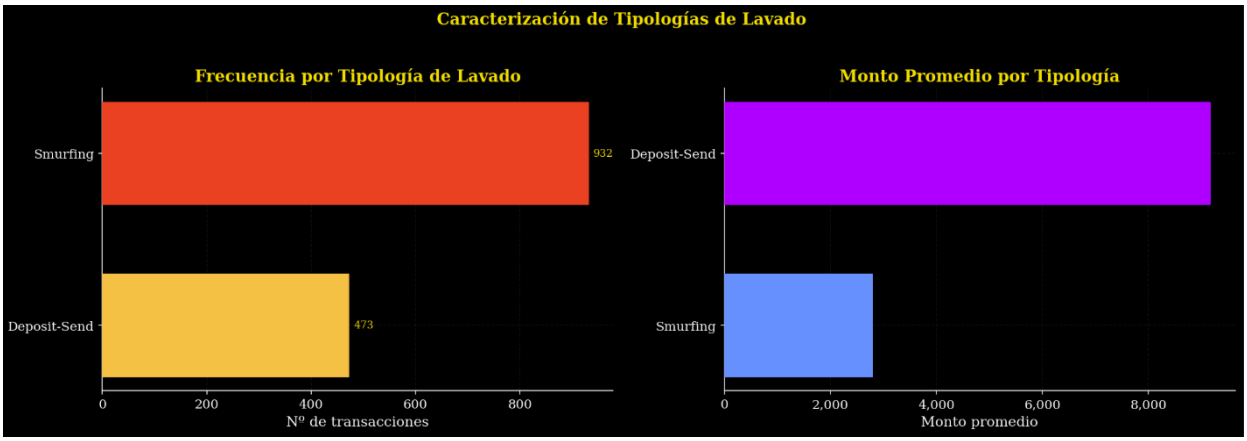


Figura 3-6: Caracterización de las tipologías de lavado: (izq.) frecuencia por tipología, (der.) monto promedio por tipología. El *Smurfing* es más frecuente pero involucra montos menores que *Deposit-Send*.

Análisis de concentración de cuentas

El análisis a nivel de cuenta emisora revela un patrón notable en el que, de las 24,328 cuentas únicas en el dataset, únicamente 536 (2.2 %) registran al menos una transacción ilícita. Más aún, la totalidad de estas 536 cuentas presentan una tasa de lavado del 100 %, lo que indica que en este conjunto de datos existe una separación completa a nivel de cuenta, es decir, no se observan cuentas que mezclen transacciones legítimas e ilícitas. Este hallazgo tiene implicaciones importantes para el modelamiento, ya que sugiere que

la identidad de la cuenta podría ser un predictor extremadamente fuerte, pero también advierte sobre el riesgo de sobreajuste si se incluye directamente como *feature*.

La Figura **3-7** muestra las 15 cuentas emisoras con mayor volumen de transacciones ilícitas. La cuenta con mayor actividad registra 30 transacciones de lavado, todas ellas constituyendo el total de su operación.

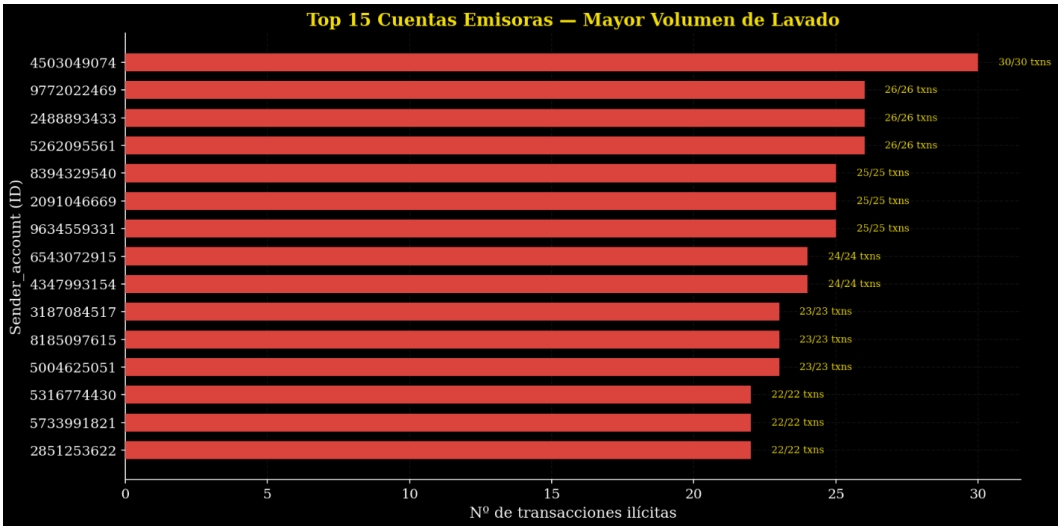


Figura 3-7: Las 15 cuentas emisoras con mayor volumen de transacciones ilícitas. La anotación *n/n txns* indica que la totalidad de transacciones de cada cuenta corresponden a lavado.

Correlación y pruebas estadísticas

Para cuantificar la asociación entre las variables disponibles y la variable objetivo, se aplicaron pruebas de correlación *point-biserial* para las variables numéricas y pruebas de independencia χ^2 para las variables categóricas. Los resultados se resumen en la Tabla **3-3**.

Tabla 3-3: Pruebas de asociación con la variable objetivo `Is_laundering`.

Variable	Prueba	Estadístico	p-value	Efecto	Sig.
`Amount`	Point-biserial	$r_{pb} = 0.1385$	$< 10^{-16}$	---	***
`Hour`	Point-biserial	$r_{pb} = 0.0159$	$4{,}71 \times 10^{-14}$	---	***
`Payment_currency`	χ^2	8.5	0.749	$V = 0.006$	n.s.
`Received_currency`	χ^2	22.3	0.035	$V = 0.010$	*
`Sender_bank_loc.`	χ^2	0.0	1.000	$V = 0.000$	n.s.
`Receiver_bank_loc.`	χ^2	644.2	$4{,}01 \times 10^{-142}$	$V = 0.054$	***

La variable `Amount` muestra la correlación *point-biserial* más fuerte ($r_{pb} = 0{,}1385$, $p < 10^{-16}$), confirmando estadísticamente la diferencia de montos observada en el análisis descriptivo. La variable `Hour`, si bien es estadísticamente significativa, presenta una correlación lineal débil ($r_{pb} = 0{,}0159$), lo cual se explica por la naturaleza no lineal de la relación temporal, en donde la tasa de lavado no crece linealmente con la hora, sino que presenta discontinuidades marcadas en los horarios nocturnos y de fin de semana.

Entre las variables categóricas, `Receiver_bank_location` presenta la asociación más fuerte ($\chi^2 = 644{,}2$, V de Cramér $= 0.054$, $p < 10^{-142}$), lo que indica que la jurisdicción del banco receptor es un factor relevante para discriminar transacciones ilícitas. Las variables de divisa presentan asociaciones débiles o no significativas, lo cual es esperable dado que la gran mayoría de transacciones (>98 %) se realizan en libras esterlinas que corresponde a la moneda local en el contexto de esta base de datos.

Síntesis del análisis exploratorio

El análisis exploratorio de los depósitos en efectivo revela varias características que fundamentarán las decisiones de diseño del modelo predictivo, las cuales se describen a continuación:

1. Existe un **desbalance severo de clases** (ratio 159.3:1), que requiere el uso de técnicas de muestreo y métricas de evaluación apropiadas para problemas altamente desbalanceados.
2. **El monto transaccional podría utilizarse como principal predictor** dado que tiene una diferencia relativa del 131.3 % entre las medias de ambas clases y una correlación *point-biserial* significativa.
3. Existen **patrones temporales discriminativos fuertes**, particularmente la concentración de actividad ilícita en horarios nocturnos y fines de semana, que sugieren la ingeniería de variables temporales como *features* del modelo.
4. Existe una **separación completa a nivel de cuenta**, en donde las 536 cuentas involucradas en lavado presentan una tasa ilícita del 100 %, lo cual demanda precaución en el tratamiento de identificadores para evitar condiciones de sobreajuste.
5. Se evidencian dos **tipologías de lavado diferenciadas** (*Smurfing* y *Deposit-Send*) con perfiles de monto distintos, lo que podría justificar un enfoque de modelamiento que capture esta heterogeneidad.

3.3 Ingeniería de características

La representación de cada transacción financiera como un vector de características cuantificables constituye el paso central del pipeline propuesto. Dado que el modelo de detección empleado basado en Isolation Forest opera exclusivamente sobre el espacio numérico de atributos, la calidad predictiva del sistema depende en gran medida de la capacidad de dichas variables para capturar los patrones de comportamiento asociados al lavado de activos. Con este fin, se diseñó la función `build_features()`, que transforma el conjunto de transacciones sin procesar en una representación de alta dimensión organizada en seis bloques temáticos que se describen en detalle a continuación:

Bloque 1: Variables Geográficas y de Divisa

El primer bloque cuantifica el contexto geopolítico y monetario de cada transacción mediante tres indicadores binarios. La variable `same_currency` toma el valor 1 cuando la moneda en que se origina el pago coincide con la moneda en que se acredita en el receptor, y 0 en caso contrario:

$$\texttt{same_currency}_i = \mathbf{1}\left[c_i^{\text{pago}} = c_i^{\text{recibido}}\right], \tag{3-1}$$

donde $\mathbf{1}[\cdot]$ denota la función indicadora. Las operaciones con cambio de divisa introducen intermediarios adicionales (casas de cambio, bancos corresponsales) que pueden ser explotados como capas de opacidad en esquemas de lavado basados en conversión de moneda.

De manera análoga, `same_country` indica si la entidad bancaria del emisor y la del receptor se encuentran en la misma jurisdicción territorial:

$$\texttt{same_country}_i = \mathbf{1}\left[\ell_i^{\text{emisor}} = \ell_i^{\text{receptor}}\right], \tag{3-2}$$

siendo ℓ la ubicación geográfica del banco. A partir de este indicador se deriva de forma complementaria la variable `is_cross_border`:

$$\texttt{is_cross_border}_i = 1 - \texttt{same_country}_i, \tag{3-3}$$

que señala explícitamente las transferencias transfronterizas. Esta característica es de especial relevancia en el contexto del *Trade-Based Money Laundering* (TBML) y de la integración mediante jurisdicciones de baja supervisión regulatoria *Financial Action Task Force* [2006].

Bloque 2: Variables Temporales

El segundo bloque extrae el contexto cronológico de cada transacción bajo la premisa de que los patrones de lavado exhiben distribuciones temporales sistemáticamente distintas a las de la actividad financiera legítima *Ngai et al.* [2011]. En ese sentido, se definen las siguientes cuatro variables:

1. **Día de la semana** (`day_of_week`): Variable discreta en $\{0, 1, \ldots, 6\}$ que codifica el día de la semana según la convención ISO 8601, donde 0 corresponde al lunes y 6 al domingo. Permite al modelo capturar diferencias en los perfiles de actividad intrasemanal de cada cuenta.

2. **Indicador de fin de semana** (`is_weekend`): Variable categórica binaria que surge debido a que las operaciones en sábado o domingo se realizan fuera del horario de supervisión habitual de los equipos de cumplimiento y, en muchos sistemas interbancarios, con retrasos en los mecanismos de compensación, lo que dificulta la detección en tiempo real. La variable se calcula como:

$$\texttt{is_weekend}_i = \mathbf{1}[\texttt{day_of_week}_i \geq 5]\,. \tag{3-4}$$

3. **Indicador nocturno** (`is_night`): Variable categórica binaria que surge debido a que la ventana nocturna [22:00, 06:00] se corresponde con el periodo fuera del horario bancario convencional, frecuentemente explotado para fines ilícitos. La variable se calcula como:

$$\texttt{is_night}_i = \mathbf{1}[h_i \geq 22 \ \vee \ h_i \leq 6]\,, \tag{3-5}$$

   donde $h_i \in \{0, 1, \ldots, 23\}$ es la hora en formato de 24 horas.

4. **Mes del año** (`month`): Variable discreta que codifica los meses del año en $\{1, \ldots, 12\}$ que permite capturar estacionalidad en los patrones de lavado, relacionada con ciertos calendarios fiscales o regulatorios.

Bloque 3: Variables de Estructuración

El *structuring*, también conocido como *smurfing*, consiste en la fragmentación deliberada de grandes sumas en múltiples transacciones de monto inferior al umbral que obliga a las instituciones financieras a presentar un informe de operación sospechosa (SAR, por sus siglas en inglés). En el Reino Unido, dicho umbral se fija en $\tau = £10{,}000$ conforme a la *Proceeds of Crime Act* de 2002 *Her Majesty's Government* [2002].Para capturar este fenómeno se definen cuatro variables que se describen a continuación:

1. Se define la variable `in_structuring_zone` que identifica transacciones individuales cuyo monto se sitúa en la zona de riesgo amplia, entre el 70 % y el 99 % del umbral:

$$\texttt{in_structuring_zone}_i = \mathbf{1}[0{,}70\,\tau \leq A_i < 0{,}99\,\tau]\,, \tag{3-6}$$

   siendo A_i el monto de la transacción i.

2. Se define la variable `just_below_threshold` que define la zona de riesgo estrecha, entre el 90 % y el 99 % del umbral, intervalo en el que la probabilidad de ocurrencia aleatoria es sustancialmente menor:

$$\texttt{just_below_threshold}_i = \mathbf{1}[0{,}90\,\tau \leq A_i < 0{,}99\,\tau]\,. \tag{3-7}$$

3. Adicionalmente, se definen dos indicadores de redondeo que señalan montos exactamente divisibles por 100 y por 1,000, respectivamente:

$$\texttt{is_round_100}_i = \mathbf{1}[A_i \bmod 100 = 0]\,, \qquad \texttt{is_round_1000}_i = \mathbf{1}[A_i \bmod 1000 = 0]\,. \tag{3-8}$$

Los montos perfectamente redondos son atípicos en transacciones comerciales legítimas, donde los importes reflejan precios con impuestos, comisiones o tipos de cambio que raramente producen cifras sin decimales. La presencia conjunta de redondez y posición próxima al umbral representa, por tanto, una señal complementaria de estructuración intencionada.

Bloque 4: Variables de Ventana Deslizante

El cuarto bloque es el más extenso del pipeline. Su objetivo es enriquecer cada transacción con estadísticas acumuladas del comportamiento reciente del emisor, transformando el problema de detección puntual en uno contextualmente informado. Para cada cuenta emisora s y cada transacción i con fecha t_i, se define el conjunto de transacciones previas comprendidas en una ventana temporal de amplitud w:

$$\mathcal{W}_i^w = \{j : \texttt{Sender}_j = s,\ t_i - w < t_j \leq t_i\}\,, \tag{3-9}$$

con $w \in \{3\text{d}, 7\text{d}, 14\text{d}, 30\text{d}\}$. Sobre este conjunto se calculan seis estadísticas, identificadas con el sufijo correspondiente a cada ventana:

$$\texttt{amt_sum}_i^w = \sum_{j \in \mathcal{W}_i^w} A_j, \tag{3-10}$$

$$\texttt{amt_mean}_i^w = \frac{\texttt{amt_sum}_i^w}{|\mathcal{W}_i^w|}, \tag{3-11}$$

$$\texttt{amt_max}_i^w = \max_{j \in \mathcal{W}_i^w} A_j, \tag{3-12}$$

$$\texttt{amt_std}_i^w = \sqrt{\frac{1}{|\mathcal{W}_i^w| - 1} \sum_{j \in \mathcal{W}_i^w} (A_j - \texttt{amt_mean}_i^w)^2}, \tag{3-13}$$

$$\texttt{tx_count}_i^w = |\mathcal{W}_i^w|\,, \tag{3-14}$$

$$\texttt{amt_accel}_i^w = \text{clip}\left(\frac{\texttt{amt_sum}_i^w - \texttt{amt_sum}_{i-1}^w}{\texttt{amt_sum}_{i-1}^w + \varepsilon},\ -5,\ 5\right), \tag{3-15}$$

donde $\varepsilon = 10^{-6}$ es una constante de estabilidad numérica que previene divisiones por cero, y la función $\text{clip}(x, a, b) = \max(a, \min(b, x))$ limita el rango de la aceleración para mitigar el efecto de casos degenerados cuando el denominador es próximo a cero.

La suma acumulada $\texttt{amt_sum}^w$ cuantifica el volumen total movilizado por el emisor en la ventana y actúa como indicador directo de acumulación de actividad. La desviación estándar $\texttt{amt_std}^w$ es especialmente informativa debido a que valores bajos con frecuencia alta indican transacciones de montos casi idénticos, patrón característico de la estructuración automatizada. La aceleración $\texttt{amt_accel}^w$ captura la tasa de cambio relativa del volumen entre observaciones consecutivas de la misma cuenta, un incremento brusco señala la activación repentina de un esquema, mientras que valores negativos sostenidos son propios de la fase de enfriamiento posterior.

A partir de las estadísticas de ventana se derivan tres variables adicionales de alto valor diagnóstico. La primera es el `structuring_3d_flag`, que traslada el análisis de estructuración desde el nivel transaccional individual al nivel de volumen acumulado en tres días:

$$\texttt{structuring_3d_flag}_i = \mathbf{1}\left[0{,}85\,\tau \leq \texttt{amt_sum}_i^{3\text{d}} < 1{,}10\,\tau\right]. \tag{3-16}$$

La segunda es el `speed_ratio_3d_7d`, que cuantifica la proporción del volumen de siete días concentrada en los últimos tres:

$$\texttt{speed_ratio_3d_7d}_i = \frac{\texttt{amt_sum}_i^{3\text{d}}}{\texttt{amt_sum}_i^{7\text{d}} + \varepsilon}. \tag{3-17}$$

Un valor próximo a 1 indica que prácticamente toda la actividad semanal se concentró en el subperiodo más reciente, señal de una escalada súbita de operaciones. La tercera variable, calculada para las ventanas de 7 y 30 días, es el ratio entre el máximo y la media, que mide la concentración del volumen total en una única transacción dominante:

$$\texttt{max_mean_ratio}_i^w = \frac{\texttt{amt_max}_i^w}{\texttt{amt_mean}_i^w + \varepsilon}. \tag{3-18}$$

Cuando este cociente es igual a 1 todas las transacciones tienen el mismo monto (uniformidad perfecta, indicativa de automatización) mientras que, cuando es significativamente mayor que 1, el volumen de la ventana está dominado por un único evento de gran tamaño.

Bloque 5: Puntuación de Anomalía por Cuenta

El quinto bloque introduce una medida de anomalía relativa al perfil histórico propio de cada cuenta emisora, en contraste con las comparaciones globales que mezclan perfiles heterogéneos de clientes. Para cada cuenta s, se computan la media y la desviación estándar poblacional de todos sus montos en el dataset:

$$\mu_s = \frac{1}{N_s} \sum_{j:\,\texttt{Sender}_j = s} A_j, \qquad \sigma_s = \sqrt{\frac{1}{N_s - 1} \sum_{j:\,\texttt{Sender}_j = s} (A_j - \mu_s)^2}, \tag{3-19}$$

donde N_s es el número total de transacciones de la cuenta s. A partir de estos parámetros se define el *z-score* por cuenta:

$$\texttt{amt_zscore}_i = \frac{A_i - \mu_{s(i)}}{\sigma_{s(i)} + \varepsilon}, \tag{3-20}$$

siendo $s(i)$ la cuenta emisora de la transacción i. Esta estandarización permite detectar transacciones cuyo monto es estadísticamente inusual respecto al comportamiento habitual del propio cliente, independientemente de si dicho monto es alto o bajo en términos absolutos. Un valor $|\texttt{amt_zscore}_i| \geq 3$ constituye un outlier estadístico severo bajo el supuesto de normalidad, y representa una señal de alta prioridad para revisión.

Bloque 6: Variables de Análisis de Red

El último bloque modela el conjunto de transacciones como un grafo dirigido y ponderado $G = (V, E, \mathbf{w})$, donde V es el conjunto de cuentas bancarias, $E \subseteq V \times V$ el conjunto de pares (emisor, receptor) que han intercambiado fondos, y $\mathbf{w}\colon E \to \mathbb{R}_+$ asigna a cada arista el monto total transferido *Barabási* [2016]. Las características de grafo capturan estructuras relacionales que son invisibles desde el análisis individual de transacciones. En ese sentido, se definen las siguientes siete variables para complementar el espacio de características:

- **Grado de salida del emisor** (`sender_out_degree`): Un emisor con grado de salida elevado dispersa fondos hacia múltiples receptores distintos, comportamiento característico de cuentas distribuidoras en esquemas de LA.

$$d_s^+ = \left|\{r \in V : (s, r) \in E\}\right|. \tag{3-21}$$

- **Grado de entrada del receptor** (`recv_in_degree`): Un receptor con grado de entrada alto agrega fondos provenientes de múltiples fuentes independientes, perfil consistente con el de una *cuenta mula* que se define como un nodo consolidador que acumula fondos antes de efectuar una transferencia final hacia el destino de integración.

$$d_r^- = |\{s \in V : (s, r) \in E\}| \,. \tag{3-22}$$

- **Concentración de contraparte** (`contraparte_concentration`): Esta métrica cuantifica la fracción del flujo total del emisor dirigida a un único receptor, capturando relaciones de dependencia exclusiva entre cuentas.

$$\texttt{cc}_i = \frac{\displaystyle\sum_{j:\,\mathrm{par}(j)=\mathrm{par}(i)} A_j}{\displaystyle\sum_{j:\,\texttt{Sender}_j=s(i)} A_j + \varepsilon}, \tag{3-23}$$

donde $\mathrm{par}(i) = (s(i), r(i))$ es el par ordenado emisor-receptor de la transacción i.

- **Recurrencia del par** (`pair_tx_count`): La frecuencia histórica de un par (emisor, receptor) específico introduce información sobre la estabilidad de la relación financiera entre ambas partes. Valores extremos en cualquier dirección son informativos debido a que, una alta recurrencia combinada con montos próximos al umbral regulatorio es indicativa de estructuración sistemática, mientras que un valor unitario señala una relación de una sola transacción entre cuentas sin historial previo.

$$\texttt{pair_tx_count}_i = |\{j \in T : \mathrm{par}(j) = \mathrm{par}(i)\}| \,. \tag{3-24}$$

- **Desequilibrio de flujo** (`flow_imbalance`): Este cociente cuantifica la asimetría entre el tamaño típico de las operaciones del emisor y el del receptor. Valores muy alejados de la unidad pueden señalar interacciones entre cuentas con perfiles de escala radicalmente distintos, como ocurre cuando un pequeño recolector aporta su fracción a una cuenta agregadora de gran volumen en un esquema clásico de LA.

$$\texttt{flow_imbalance}_i = \frac{\bar{A}_{s(i)}}{\bar{A}_{r(i)} + \varepsilon}, \tag{3-25}$$

donde $\bar{A}_v$ es el monto promedio de todas las transacciones asociadas al nodo $v \in V$.

- **Indicador de nodo hub** (`recv _is _hub`): Esta variable binaria identifica transacciones cuyo receptor pertenece al 5 % de cuentas con mayor número de fuentes distintas, facilitando al modelo el reconocimiento de nodos centrales en redes de lavado.

$$\texttt{recv_is_hub}_i = \mathbf{1}\left[d^-_{r(i)} > Q_{0,95}(d^-)\right], \tag{3-26}$$

donde $Q_{0,95}(d^-)$ es el percentil 95 de la distribución empírica del grado de entrada en el grafo.

- **Monto relativo al receptor** (`amt _vs _recv _mean`): Análoga al z-score del bloque anterior pero orientada al receptor, esta variable detecta transacciones cuyo importe es desproporcionado respecto al tamaño habitual de las operaciones que la cuenta receptora suele procesar, una señal indicativa de un cambio abrupto en el uso de dicha cuenta.

$$\texttt{amt_vs_recv_mean}_i = \frac{A_i}{\bar{A}_{r(i)} + \varepsilon}. \tag{3-27}$$

Síntesis del Espacio de Características

El conjunto resultante de la función `build_features()` comprende 46 variables que cubren seis dimensiones analíticas de muy alta relevancia en el contexto de AML (contexto geográfico, el comportamiento temporal, la proximidad a umbrales regulatorios y posible estructuración, dinámica histórica de la cuenta, comportamientos anómalos en cuentas y la estructura relacional del grafo transaccional). Esta representación multidimensional es especialmente adecuada para modelos basados en el algoritmo Isolation Forest, cuyo mecanismo de detección, que se basa en la longitud media de camino necesaria para aislar una observación mediante particiones binarias aleatorias, se beneficia de un espacio de características donde las transacciones anómalas son, en promedio, más fáciles de separar del conjunto mayoritario *Liu et al.* [2008].

La construcción deliberada de variables que amplifican las diferencias comportamentales entre transacciones legítimas y sospechosas refuerza esta propiedad, reduciendo el número esperado de particiones requeridas para aislar los puntos anómalos y, por tanto, mejorando el poder discriminativo del modelo, objetivo final del presente trabajo.

4 Implementación del modelo de aprendizaje automático

Con el espacio de características construido en el capítulo anterior, este capítulo aborda la implementación operativa del modelo de detección de anomalías. La elección del algoritmo *Isolation Forest* como núcleo del sistema responde a tres consideraciones fundamentales discutidas en el marco teórico: su naturaleza no supervisada, que evita la dependencia de etiquetas exhaustivas, escasas en el dominio AML; su complejidad computacional aproximadamente lineal en el número de observaciones, lo que lo hace adecuado para los volúmenes característicos del monitoreo transaccional; y su desempeño competitivo reportado en la literatura sobre datos financieros de alta dimensionalidad. El capítulo se estructura en tres secciones. La primera describe el proceso de entrenamiento del modelo, incluyendo la selección de variables, la estimación del parámetro de contaminación y la estandarización de la matriz de atributos. La segunda profundiza en el algoritmo *Isolation Forest*, detallando la estructura de los árboles de aislamiento, el cálculo de las puntuaciones de anomalía y la justificación de los hiperparámetros adoptados. La tercera sección aborda el problema crítico de la selección del umbral de clasificación, evaluando sistemáticamente cuatro criterios alternativos y fundamentando la elección final del criterio F_β con $\beta = 2$ como regla de decisión operacional.

4.1 Entrenamiento del Modelo

Una vez construido el espacio de características descrito en el capítulo anterior, el proceso de entrenamiento del modelo comprende cuatro etapas secuenciales: la selección y preparación de la matriz de atributos, la estimación del parámetro de contaminación, la estandarización de las variables y, finalmente, el ajuste del modelo de Isolation Forest y la obtención de las puntuaciones de anomalía. Cada una de estas etapas se detalla a continuación.

Selección de Variables y Construcción de la Matriz de Atributos

De la totalidad de variables generadas por el pipeline de ingeniería de características, se selecciona un subconjunto de $p = 46$ variables para conformar la matriz de atributos $\mathbf{X} \in \mathbb{R}^{n \times p}$, donde n es el número total de transacciones en el conjunto de datos. La selección está guiada por criterios de relevancia semántica, cobertura multidimensional del fenómeno y múltiples ejercicios de experimentación. Las variables seleccionadas pueden organizarse en los siguientes grupos:

1. **Atributos de la transacción base** (4 variables): El monto de la operación (`Amount`) y los tres indicadores geográfico-monetarios (`same_currency`, `same_country`, `is_cross_border`) descritos en la Sección 3.3. Estas variables aportan el contexto inmediato e intrínseco de cada transacción, sin dependencia de información histórica.

2. **Atributos temporales** (3 variables): `is_weekend`, `is_night` y `month`, definidos en la Sección 3.3. Estas variables capturan irregularidades en el calendario de operación que son indicativas de actividad fuera del horario de supervisión habitual.

3. **Atributos de estructuración** (6 variables): Los cuatro indicadores explicados en la Sección 3.3 (`is_round_100`, `is_round_1000`, `in_structuring_zone`, `just_below_threshold`) más la variable de estructuración acumulada en tres días (`structuring_3d_flag`) y el ratio de velocidad (`speed_ratio_3d_7d`). En conjunto, estas variables permiten detectar tanto el fraccionamiento individual de montos como su efecto acumulado en el corto plazo.

4. **Estadísticas de ventana deslizante** (25 variables): Para las ventanas de 3, 7, 14 y 30 días se incluyen la suma, la media, el máximo y la desviación estándar del monto, así como el conteo de transacciones. Para las ventanas de 7, 14 y 30 días se añaden adicionalmente la aceleración (`amt_accel`) y, para las de 7 y 30 días, el ratio máximo-media (`max_mean_ratio`). Estas variables proveen al modelo de información sobre la dinámica temporal del flujo de fondos a distintas escalas.

5. **Puntuación de anomalía histórica** (1 variable): El z-score por cuenta (`amt_zscore`), definido en la Sección 3.3, que normaliza el monto de cada transacción respecto al perfil histórico propio del emisor.

6. **Atributos de red** (7 variables): El conjunto completo de métricas de grafo definidas en la Sección 3.3: `sender_out_degree`, `recv_in_degree`, `contraparte_concentration`, `pair_tx_count`, `flow_imbalance`, `recv_is_hub` y `amt_vs_recv_mean`.

Los valores faltantes (`NaN`) que pudieran subsistir tras el pipeline de ingeniería de variables son reemplazados por cero antes de la construcción de $\mathbf{X}$. Esta imputación es conservadora y semánticamente coherente dado que, en la mayoría de los casos, un valor ausente corresponde a ventanas temporales con actividad nula o a cuentas con una sola transacción para las que estadísticas como la desviación estándar no están definidas, en ese sentido, sustituirlos por cero es equivalente a codificar la ausencia de actividad previa.

El vector de etiquetas verdaderas $\mathbf{y} \in \{0,1\}^n$, donde $y_i = 1$ indica una transacción de lavado confirmada, es extraído paralelamente y se utiliza exclusivamente para la estimación del parámetro de contaminación y para la evaluación posterior del modelo. Evidentemente este vector no interviene en el ajuste del mismo, dado el carácter no supervisado del modelo desarrollado basado en el algoritmo Isolation Forest.

Estimación del Parámetro de Contaminación

El parámetro de contaminación ρ representa la proporción esperada de anomalías en el conjunto de datos y determina el umbral de decisión a partir del cual el modelo clasifica una observación como anómala. Formalmente, dado un umbral de puntuación δ_ρ tal que exactamente una fracción ρ de las observaciones de entrenamiento supera dicho umbral, la regla de clasificación binaria del modelo se define como:

$$\hat{y}_i = \begin{cases} 1 & \text{si } \texttt{score}_i > \delta_\rho \\ 0 & \text{en caso contrario,} \end{cases} \tag{4-1}$$

donde $\texttt{score}_i$ es la puntuación de anomalía de la transacción i, definida en la Sección 4.2.

En lugar de fijar ρ de forma arbitraria, se estima directamente a partir de la prevalencia empírica de lavado en el conjunto etiquetado:

$$\hat{\rho} = \text{clip}\left(\frac{1}{n} \sum_{i=1}^{n} y_i,\ 0{,}001,\ 0{,}5 \right), \tag{4-2}$$

donde la función $\text{clip}(x, a, b) = \text{máx}(a, \text{mín}(b, x))$ garantiza que el parámetro permanezca en el intervalo admisible (0, 0,5) requerido por la implementación. El límite inferior de 0,001 previene la degeneración del umbral cuando la tasa de lavado es extremadamente baja, mientras que el límite superior de 0,5 impone la restricción semántica de que las anomalías no pueden constituir la mayoría del conjunto de datos.

Esta estrategia de estimación tiene una justificación doble. En primer lugar, es metodológicamente más rigurosa que una elección ad hoc de ρ, ya que ancla el umbral de decisión en la estructura real de los datos. En segundo lugar, al derivarse directamente de la prevalencia observada, el parámetro se actualiza automáticamente si el pipeline se reaplica a datasets con diferentes tasas de anomalía, dotando al sistema de adaptabilidad sin intervención manual.

Estandarización de Variables

Previo al ajuste del modelo, todas las variables de $\mathbf{X}$ son sometidas a una transformación de estandarización mediante un escalador de varianza unitaria (*StandardScaler*). Para cada variable $k \in \{1, \ldots, p\}$, la transformación se define como:

$$x_{ik}^* = \frac{x_{ik} - \hat{\mu}_k}{\hat{\sigma}_k}, \tag{4-3}$$

donde $\hat{\mu}_k$ y $\hat{\sigma}_k$ son la media y la desviación estándar muestral de la k-ésima variable calculadas sobre el conjunto de entrenamiento completo:

$$\hat{\mu}_k = \frac{1}{n}\sum_{i=1}^{n} x_{ik}, \qquad \hat{\sigma}_k = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_{ik} - \hat{\mu}_k)^2}. \tag{4-4}$$

La transformación produce una matriz estandarizada $\mathbf{X}^* \in \mathbb{R}^{n \times p}$ donde, para cada columna, $\hat{\mu}_k^* \approx 0$ y $\hat{\sigma}_k^* \approx 1$.

Aunque el algoritmo Isolation Forest es teóricamente invariante a transformaciones afines de las variables individuales, dado que sus particiones son paralelas a los ejes y no dependen de distancias euclidianas, la estandarización cumple un papel relevante en el presente pipeline por dos razones. En primer lugar, la selección aleatoria de puntos de corte dentro del rango de cada variable implica que variables con rangos muy amplios (como `amt_sum_30d`, que puede superar varios órdenes de magnitud a variables binarias) dominarían de facto la probabilidad de ser seleccionadas como variable de partición en cada nodo del árbol, introduciendo un sesgo implícito de selección de atributos. La estandarización homogeniza los rangos y garantiza que todas las variables tengan una probabilidad comparable de contribuir a las particiones. En segundo lugar, cuando se activa la selección de subespacio aleatorio mediante el parámetro `max_features` (descrito en la siguiente sección), la interpretación de la diversidad del subespacio es más consistente cuando las variables se encuentran en escalas comparables.

Los parámetros $\hat{\mu}_k$ y $\hat{\sigma}_k$ son almacenados junto al modelo entrenado para garantizar que cualquier transacción futura sea estandarizada con los mismos parámetros del ajuste, evitando la fuga de información entre conjuntos de datos.

4.2 Ajuste del Modelo de Isolation Forest

El algoritmo Isolation Forest *Liu et al.* [2008] funciona para problemas de detección de anomalías basado en el principio de que las observaciones anómalas son intrínsecamente más fáciles de aislar que las normales, bajo el entendido de que requieren, en promedio, menos particiones binarias aleatorias para quedar separadas del resto del conjunto. El modelo construye un ensamble de T árboles de aislamiento (*isolation trees*) de forma totalmente no supervisada, sin hacer uso del vector de etiquetas $\mathbf{y}$.

Estructura de un Árbol de Aislamiento

Cada árbol de aislamiento $\mathcal{T}_t$ se construye mediante el siguiente procedimiento aleatorio. Dado un subconjunto de entrenamiento $\mathbf{X}_t \subseteq \mathbf{X}^*$ de tamaño ψ (tamaño de muestra por árbol), se selecciona una variable k uniformemente al azar entre las $q = \lfloor 0{,}8p \rfloor$ variables del subespacio activo, y se genera un punto de corte ξ uniformemente distribuido en el rango observado de dicha variable en el subconjunto actual:

$$k \sim \mathcal{U}\{1, \ldots, q\}, \qquad \xi \sim \mathcal{U}\left[\min_{i \in \mathbf{X}_t} x_{ik}^*,\ \max_{i \in \mathbf{X}_t} x_{ik}^*\right]. \tag{4-5}$$

La partición divide $\mathbf{X}_t$ en dos subconjuntos: $\{i : x_{ik}^* < \xi\}$ y $\{i : x_{ik}^* \geq \xi\}$, y el proceso se repite recursivamente en cada rama hasta que cada nodo hoja contiene una única observación o se alcanza la

profundidad máxima del árbol. La longitud del camino $h_t(i)$ de la observación i en el árbol $\mathcal{T}_t$ se define como el número de aristas traversadas desde la raíz hasta el nodo hoja que contiene a i.

Puntuación de Anomalía

La puntuación de anomalía normalizada para la observación i se obtiene promediando las longitudes de camino sobre los T árboles del ensamble y comparando dicho promedio con la longitud de camino esperada para un árbol construido sobre ψ puntos aleatorios. Formalmente:

$$s(i, \psi) = 2^{-\dfrac{E_t[h_t(i)]}{c(\psi)}}, \tag{4-6}$$

donde $E_t[h_t(i)] = \frac{1}{T}\sum_{t=1}^{T} h_t(i)$ es la longitud de camino media, y $c(\psi)$ es la longitud de camino media esperada en un árbol binario de búsqueda construido sobre ψ puntos:

$$c(\psi) = 2\,H(\psi - 1) - \frac{2(\psi - 1)}{\psi}, \tag{4-7}$$

siendo $H(k) = \ln(k) + \gamma_{\text{EM}}$ la aproximación de la suma armónica mediante el logaritmo natural y la constante de Euler-Mascheroni $\gamma_{\text{EM}} \approx 0{,}5772$. El rango de $s(i, \psi)$ es $(0, 1)$ en donde valores próximos a 1 indican longitudes de camino anormalmente cortas, lo que equivale a mayor facilidad de aislamiento y, por tanto, mayor grado de anomalía.

En la implementación, se invierte el signo de la función `score_samples` del modelo (que internamente retorna $-s(i, \psi)$) para obtener una puntuación directamente proporcional al grado de anomalía:

$$\texttt{anomaly_score}_i = -\texttt{score_samples}(\mathbf{x}_i^*) = s(i, \psi), \tag{4-8}$$

de forma que valores elevados de `anomaly_score` corresponden inequívocamente a transacciones más sospechosas.

Hiperparámetros del Modelo

La configuración del modelo se especifica mediante los siguientes hiperparámetros, cuya elección obedece a consideraciones tanto teóricas como computacionales:

- **Número de árboles** (`n_estimators` $= T = 500$): Liu et al. *Liu et al.* [2008] demuestran que la puntuación de anomalía converge con rapidez al aumentar T. En la práctica, valores a partir de 100 suelen ser suficientes para conjuntos de datos de tamaño moderado. Se adopta $T = 500$ para garantizar la estabilidad de la estimación en un dataset transaccional con alta variabilidad intraclase, aceptando el incremento proporcional en el costo computacional.

- **Tamaño de muestra por árbol** (`max_samples` = `'auto'`): La opción `'auto'` fija $\psi = \text{mín}(256, n)$. El valor 256 fue propuesto en el artículo original *Liu et al.* [2008] como un valor óptimo que es lo suficientemente grande para capturar la estructura local del conjunto de datos, pero lo bastante pequeño para que los árboles sean construidos rápidamente y con alta diversidad. En la práctica, para conjuntos de datos financieros con $n \gg 256$, esta elección implica que cada árbol ve menos del 1 % de los datos, lo que promueve la variabilidad entre árboles y reduce el sobreajuste.

- **Contaminación** (`contamination` $= \hat{\rho}$): Estimada empíricamente según la ecuación (4-2), este parámetro fija el umbral $\delta_{\hat{\rho}}$ sobre la distribución de puntuaciones del conjunto de entrenamiento de forma que exactamente una fracción $\hat{\rho}$ de las observaciones sea etiquetada como anómala.

- **Fracción de subespacio** (`max_features` = 0,8): En cada nodo de cada árbol, la variable de partición se selecciona al azar entre un subconjunto activo de $q = \lfloor 0{,}8 \times p \rfloor = \lfloor 0{,}8 \times 46 \rfloor = 36$ variables. Esta técnica de submuestreo de atributos, análoga a la empleada en Random Forest *Breiman* [2001], incrementa la diversidad entre los árboles del ensamble, debido a que cada árbol explora un subespacio diferente, y reduce la correlación entre sus puntuaciones individuales, mejorando la precisión del estimador conjunto. El valor 0.8 retiene suficiente información en cada árbol sin sacrificar la diversidad del ensamble.

- **Muestreo con reemplazamiento** (`bootstrap` = `True`): Habilita el muestreo *bootstrap* al construir el subconjunto $\mathbf{X}_t$ de cada árbol, de modo que cada observación puede aparecer más de una vez en el mismo árbol y, con probabilidad $e^{-1} \approx 0{,}368$, de quedar fuera del árbol por completo. Esta aleatoriedad adicional contribuye a la decorrelación entre árboles, complementando el efecto de `max_features`.

- **Semilla aleatoria** (`random_state` = `RANDOM_STATE`): Fija la semilla del generador pseudoaleatorio para garantizar la reproducibilidad exacta de los resultados. Todos los elementos estocásticos del modelo (selección de muestras, selección de variables y generación de puntos de corte) quedan determinados por este valor.

- **Paralelización** (`n_jobs` = -1): La construcción de los $T = 500$ árboles es un proceso paralelo, puesto que cada árbol se ajusta de forma independiente. El valor -1 instruye a la implementación para que utilice la totalidad de los núcleos de procesamiento disponibles, reduciendo el tiempo de ajuste en un factor proporcional al número de núcleos.

La Tabla **4-1** resume los hiperparámetros adoptados y su una justificación breve de la selección de los mismos.

Hiperparámetro	**Valor**	**Justificación**
`n_estimators`	500	Estabilidad de la puntuación promedio
`max_samples`	`'auto'` ($\psi = 256$)	Diversidad y eficiencia según Liu et al. *Liu et al.* [2008]
`contamination`	$\hat{\rho}$ (empírico)	Umbral de decisión anclado en la prevalencia real
`max_features`	0.8	Decorrelación por submuestreo de atributos
`bootstrap`	`True`	Diversidad adicional por muestreo con reemplazamiento
`random_state`	fijo	Reproducibilidad
`n_jobs`	-1	Uso completo de recursos de cómputo

Tabla 4-1: Hiperparámetros del modelo Isolation Forest y su justificación.

Obtención de las Puntuaciones de Anomalía

Una vez ajustado el modelo sobre la matriz estandarizada $\mathbf{X}^*$, se computa la puntuación de anomalía para cada transacción del conjunto de datos según la ecuación (4-8). La distribución resultante de puntuaciones, almacenada en la columna `anomaly_score` del dataset, constituye la salida primaria del modelo y es el insumo sobre el que se construyen las métricas de evaluación y el umbral de clasificación operacional.

Es importante destacar que el modelo es ajustado e inferido sobre el mismo conjunto de datos (*transductive setting*). Esta decisión es habitual en aplicaciones de detección de anomalías en contextos donde la partición estricta en conjuntos de entrenamiento y prueba reduciría severamente el volumen de datos disponibles para el ajuste del ensamble. La evaluación del rendimiento discriminativo del modelo se lleva a cabo, no

obstante, de forma rigurosa mediante las métricas descritas en la sección siguiente, haciendo uso del vector de etiquetas $\mathbf{y}$ como referencia externa.

La puntuación de anomalía resultante puede interpretarse como una medida continua de sospecha en la medida en que, cuanto mayor es su valor, menor es la longitud de camino media necesaria para aislar la transacción en el ensamble de árboles y, por tanto, mayor es la probabilidad de que dicha transacción pertenezca a la cola de comportamientos atípicos asociados al lavado de activos.

4.3 Selección de Umbral de Clasificación

El modelo basado en el algoritmo Isolation Forest produce, para cada transacción i, una puntuación de anomalía continua $\texttt{anomaly_score}_i \in (0, 1)$ según lo descrito en la Sección 4.2. Para traducir esta puntuación en una decisión binaria de alerta ($\hat{y}_i \in \{0, 1\}$), es necesario fijar un umbral de clasificación δ tal que:

$$\hat{y}_i = \mathbf{1}[\texttt{anomaly_score}_i \geq \delta]\,. \tag{4-9}$$

La elección de δ no es trivial y de hecho es uno de los puntos centrales del modelo dado que, valores bajos incrementan la sensibilidad del sistema a costa de generar un mayor número de falsas alarmas, mientras que valores altos reducen la carga operacional de revisión pero aumentan el riesgo de que transacciones ilícitas pasen inadvertidas, lo cual es evidentemente indeseable. Esta sección describe el procedimiento seguido para evaluar y comparar cuatro criterios de selección de umbral, y fundamenta la elección final del criterio adoptado.

Métricas Globales de Discriminación

Con carácter previo a la selección del umbral, se evalúa la capacidad discriminativa global del modelo mediante dos métricas que son independientes del umbral elegido, pues se calculan sobre la distribución completa de puntuaciones.

- **Área bajo la curva ROC** (AUC-ROC). La curva ROC representa la tasa de verdaderos positivos (recall, TPR) frente a la tasa de falsos positivos (FPR) al barrer todos los umbrales posibles. Formalmente:

$$\mathrm{TPR}(\delta) = \frac{\mathrm{TP}(\delta)}{\mathrm{TP}(\delta) + \mathrm{FN}(\delta)}, \qquad \mathrm{FPR}(\delta) = \frac{\mathrm{FP}(\delta)}{\mathrm{FP}(\delta) + \mathrm{TN}(\delta)}, \tag{4-10}$$

  y el área bajo esta curva se define como:

$$\text{AUC-ROC} = \int_0^1 \mathrm{TPR}\big(\mathrm{FPR}^{-1}(t)\big)\, dt. \tag{4-11}$$

  Un valor de AUC-ROC = 0,5 corresponde a un clasificador aleatorio, mientras que AUC-ROC = 1 indica discriminación perfecta. El modelo obtiene AUC-ROC = 0,8864, lo que indica una capacidad discriminativa alta y sugiere que las puntuaciones de anomalía separan efectivamente las distribuciones de transacciones legítimas e ilícitas.

- **Área bajo la curva de precisión-recall** (AUPRC). Dado el marcado desbalance de clases presente en el dataset, en donde las transacciones de lavado constituyen una fracción muy minoritaria de la población total, la curva de precisión-recall es una métrica de discriminación más informativa que la curva ROC *Saito & Rehmsmeier* [2015]. La curva PR representa la precisión frente al recall al barrer los umbrales, y su área equivale a la *Average Precision*:

$$\text{AUPRC} = \sum_{k=1}^{K} [\text{R}_k - \text{R}_{k-1}]\, \text{P}_k, \tag{4-12}$$

donde P_k y R_k son la precisión y el recall en el k-ésimo umbral evaluado. Un clasificador sin información produce AUPRC $= \hat{\rho}$ (igual a la prevalencia de la clase positiva). El modelo obtiene AUPRC = 0,2653, valor que, si bien refleja la dificultad inherente del problema bajo desbalance extremo, supera con amplitud el nivel de referencia aleatorio y constituye la **métrica principal de evaluación** del sistema, por ser la más sensible a la correcta identificación de la clase minoritaria, que en este contexto corresponden a las anomalías asociadas al LA.

Criterios de Selección de Umbral

Se evalúan cuatro criterios de selección de umbral, cada uno con una filosofía de optimización diferente. Para cada criterio se determinan analíticamente la precisión, el recall, la puntuación F_1 y el número de alertas generadas. Los resultados de esta comparativa se resumen en la Tabla **5-2**.

Criterio 1: Índice F_β con $\beta = 2$

La puntuación F_β es la media armónica ponderada de la precisión y el recall, con un factor de ponderación β que controla la importancia relativa de ambas medidas. Su definición general es:

$$F_\beta = \frac{(1+\beta^2) \cdot P \cdot R}{\beta^2 \cdot P + R}, \tag{4-13}$$

donde P denota la precisión y R el recall. Cuando $\beta = 1$ la fórmula se reduce a la F_1 estándar, que asigna igual peso a ambas métricas. Cuando $\beta = 2$, el recall recibe una ponderación cuatro veces mayor que la precisión ($\beta^2 = 4$), priorizando explícitamente la detección de verdaderos positivos sobre la minimización de falsas alarmas.

El umbral óptimo bajo este criterio se obtiene maximizando F_β sobre todos los umbrales posibles de la curva de precisión-recall:

$$\delta_{F_\beta} = \arg\max_{\delta} \frac{(1+\beta^2) \cdot P(\delta) \cdot R(\delta)}{\beta^2 \cdot P(\delta) + R(\delta) + \varepsilon}, \tag{4-14}$$

donde $\varepsilon = 10^{-8}$ es una constante de estabilidad numérica. Con $\beta = 2$ se obtiene $\delta_{F_2} = 0{,}5923$, produciendo una precisión de 0.1973, un recall de 0.4427 y un valor $F_1 = 0{,}2730$ (reportado en la Tabla **5-2**), con un total de 3,152 alertas generadas.

Criterio 2: F_1 Óptimo

El umbral de F_1 óptimo maximiza la media armónica no ponderada de precisión y recall:

$$\delta_{F_1} = \arg\max_{\delta} \frac{2 \cdot P(\delta) \cdot R(\delta)}{P(\delta) + R(\delta) + \varepsilon}. \tag{4-15}$$

Con $\delta_{F_1} = 0{,}6270$ se obtiene $P = 0{,}4602$, $R = 0{,}2512$, $F_1 = 0{,}3250$ y 767 alertas. Este umbral sacrifica recall en favor de una mayor precisión debido a que detecta una fracción menor de los casos de lavado, pero los que detecta lo hace con menor tasa de error.

Criterio 3: Índice de Youden

El índice de Youden *Youden* [1950] es una medida escalar de la eficacia diagnóstica definida sobre la curva ROC como:

$$J(\delta) = \text{TPR}(\delta) - \text{FPR}(\delta) = \text{Recall}(\delta) - (1 - \text{Especificidad}(\delta)), \tag{4-16}$$

y el umbral óptimo se obtiene como:

$$\delta_J = \arg\max_{\delta} J(\delta). \tag{4-17}$$

Con $\delta_J = 0{,}4794$ se obtiene $P = 0{,}0235$, $R = 0{,}8534$ y 51,078 alertas. El índice de Youden maximiza la diferencia entre la tasa de detección y la tasa de falsa alarma sin considerar el desbalance de clases, lo que en datasets fuertemente desbalanceados puede producir umbrales muy bajos que generan un volumen de alertas operacionalmente inmanejable.

Criterio 4: Percentil Operacional (98 %)

Este criterio define el umbral como el percentil 98 de la distribución empírica de puntuaciones:

$$\delta_{P_{98}} = Q_{0{,}98}(\texttt{anomaly_score}), \tag{4-18}$$

de forma que exactamente el 2 % de las transacciones con mayor puntuación son marcadas como alertas, independientemente de su valor absoluto. Con $\delta_{P_{98}} = 0{,}5810$ se producen 4,505 alertas, con $P = 0{,}1532$ y $R = 0{,}4911$. Este umbral tiene una interpretación puramente operacional en la medida en que fija la carga de revisión del equipo de cumplimiento en un porcentaje predeterminado del flujo total de transacciones, desacoplando la decisión del umbral del desempeño estadístico del modelo, lo cual, para efectos de este trabajo, no es la medida más adecuada.

Comparativa de Criterios

La siguiente tabla resume los cuatro criterios evaluados con sus métricas de desempeño asociadas.

Criterio	**Umbral**	**Precisión**	**Recall**	**F_1**	**Alertas**
F_β con $\beta = 2$ *(seleccionado)*	0.5923	0.1973	0.4427	0.2730	3,152
F_1 óptimo	0.6270	0.4602	0.2512	0.3250	767
Índice de Youden	0.4794	0.0235	0.8534	0.0457	51,078
Percentil 98 %	0.5810	0.1532	0.4911	0.2335	4,505

Tabla 4-2: Comparativa de criterios de selección de umbral. Métricas calculadas sobre el conjunto de datos de evaluación. AUC-ROC = 0.8864; AUPRC = 0.2653.

Justificación del Criterio Seleccionado: F_β con $\beta = 2$

El umbral final adoptado es $\delta^* = \delta_{F_2} = 0{,}5923$, correspondiente al criterio F_β con $\beta = 2$. Esta elección está fundamentada en cuatro argumentos que se desarrollan a continuación.

- **Argumento 1 ->Asimetría del costo de los errores en AML.**: En el contexto de la detección de lavado de activos, los dos tipos de error de clasificación tienen consecuencias radicalmente asimétricas.

Un falso negativo (transacción de lavado no detectada) implica la integración exitosa de fondos ilícitos en el sistema financiero, con consecuencias regulatorias, reputacionales y sociales de alto impacto. Un falso positivo (transacción legítima marcada como alerta) implica la apertura de una investigación interna que, en última instancia, puede resolverse sin consecuencias materiales. Esta asimetría es reconocida explícitamente por los marcos regulatorios internacionales, específicamente, la Recomendación 29 del GAFI *Financial Action Task Force* [2012] establece que las instituciones financieras deben implementar sistemas orientados a minimizar los falsos negativos, incluso a costa de un mayor volumen de investigaciones. La puntuación F_2, al ponderar el recall cuatro veces más que la precisión, formaliza matemáticamente esta prioridad regulatoria.

- **Argumento 2 ->Balance entre sensibilidad y viabilidad operacional.**: La inspección de la Tabla **5-2** revela que el criterio de Youden, que maximiza el recall hasta 0.8534, lo hace a un costo operacional inasumible que genera 51,078 alertas, una carga que excede con creces la capacidad de revisión manual de cualquier equipo de cumplimiento de tamaño realista. En el extremo opuesto, el criterio F_1 óptimo, que alcanza una precisión de 0.4602, solo detecta el 25.12 % de los casos de lavado, sacrificando el objetivo primario del sistema. El criterio F_2 ocupa una posición intermedia y equilibrada dado que, con 3,152 alertas y un recall de 0.4427, detecta prácticamente el doble de casos de lavado que el criterio F_1 óptimo, manteniendo un volumen de investigaciones operacionalmente manejable.

- **Argumento 3 ->Coherencia con las características del dataset.**: El dataset presenta un desbalance de clases severo en el cual la prevalencia de lavado es $\hat{\rho} \ll 0{,}5$, lo que deprime estructuralmente la precisión del sistema independientemente del umbral elegido. En estas condiciones, exigir una precisión alta mediante un umbral elevado es metodológicamente inadecuado dado que el modelo descartaría gran parte de las transacciones ilícitas para reducir los falsos positivos, precisamente en un contexto donde cada caso de lavado no detectado tiene un costo elevado. La priorización del recall que impone F_2 es, por tanto, la respuesta estadísticamente correcta ante el desbalance extremo de la clase objetivo.

- **Argumento 4 ->Consistencia con la literatura especializada.**: La adopción de métricas orientadas al recall como criterio de selección de umbral en sistemas AML está respaldada por la literatura académica y aplicada. Kute et al. *Kute et al.* [2021] y Dal Pozzolo et al. *Dal Pozzolo et al.* [2015] destacan que en detección de fraude financiero, la maximización del recall bajo restricciones de volumen de alertas es la estrategia dominante, siendo F_β con $\beta \in [2, 3]$ el rango recomendado para este tipo de aplicaciones. El valor $\beta = 2$ representa el punto de mínima penalización de recall que mantiene la precisión como componente significativo de la métrica, evitando la degeneración hacia la maximización ciega del recall que exhibe el índice de Youden.

En síntesis, el umbral $\delta^* = 0{,}5923$ derivado del criterio F_2 satisface simultáneamente los tres requisitos fundamentales de un sistema de monitoreo AML operacional: (i) detecta una fracción sustancial de las transacciones de lavado (recall = 0.4427), (ii) genera un volumen de alertas investigable por un equipo de cumplimiento (3,152 transacciones) y (iii) está alineado con la jerarquía de costos de error establecida por el marco regulatorio internacional. Las transacciones cuya puntuación de anomalía supera este umbral quedan marcadas mediante la variable binaria `alerta_lavado`, que constituye la salida final del sistema de detección.

5 Evaluación del modelo de aprendizaje automático

El presente capítulo se ocupa de la evaluación cuantitativa del modelo *Isolation Forest* implementado en el capítulo anterior, atendiendo a las particularidades metodológicas que impone un problema de extremo desbalance de clases y la naturaleza no supervisada del algoritmo. La evaluación se organiza en dos secciones complementarias. La primera presenta las métricas de desempeño obtenidas sobre el conjunto de datos completo, incluyendo medidas globales independientes del umbral (AUC-ROC, AUPRC), el análisis comparativo de los cuatro criterios de selección de umbral evaluados, la matriz de confusión asociada al umbral seleccionado y la validación temporal *out-of-time* entrenando sobre 2022 y evaluando sobre 2023, ejercicio que permite caracterizar honestamente la degradación del modelo ante *concept drift* inter-anual. La segunda sección sitúa estos resultados frente a dos modelos no supervisados de referencia, *Local Outlier Factor* y *Elliptic Envelope*, evaluados sobre el mismo espacio de 46 características, y discute la interpretación del AUPRC como métrica primaria de evaluación en escenarios de extremo desbalance de clases.

5.1 Métricas de Desempeño

La evaluación del modelo *Isolation Forest* propuesto para la detección de anomalías asociadas al lavado de activos en transacciones de tipo *Cash Deposit* se llevó a cabo mediante un conjunto de métricas seleccionadas en función de las características específicas del problema, principalmente la presencia de un extremo desequilibrio de clases y la necesidad de utilizar un algoritmo de naturaleza no supervisada. Los resultados globales del modelo se resumen en la Tabla **5-1**.

Tabla 5-1: Métricas globales de desempeño — IForest Cash Deposit

Métrica	**Valor**
AUC-ROC	0.8864
AUPRC	0.2653
Lift relativo sobre baseline aleatorio	42.5×
Umbral seleccionado (F-β, β=2)	0.5923

Capacidad discriminativa global: AUC-ROC

El modelo alcanzó un *AUC-ROC* de 0.8864, lo que indica que ante una transacción de lavado y una transacción legítima elegidas al azar, el modelo asigna un *anomaly score* superior a la primera con una probabilidad del 88.64 %. Esta interpretación probabilística del *AUC-ROC*, formalizada por *Hanley & McNeil* [1982], lo convierte en una medida de discriminación independiente del umbral de decisión, y por tanto apropiada para evaluar la calidad del *ranking* de anomalías producido por el modelo con independencia del criterio operacional que se adopte para la generación de alertas.

El valor obtenido supera el rango 0.70-0.85 reportado por *Ahmed et al.* [2016] como típico de modelos

no supervisados aplicados al dominio financiero, y es consistente con los resultados de *Puech et al.* [2019], quienes aplicaron *Isolation Forest* sobre datos bancarios reales obteniendo *AUC-ROC* en el rango 0.82-0.91 dependiendo del segmento transaccional. La distribución de *anomaly scores* por clase, presentada en la Figura **5-1**, evidencia visualmente esta separación, en la gráfica se denota que las transacciones asociadas a lavado de activos concentran sus scores en la cola derecha de la distribución, desplazadas respecto a la masa de transacciones legítimas, lo que confirma que el modelo identifica correctamente anomalías de manera diferenciada para este tipo de comportamiento ilícito.

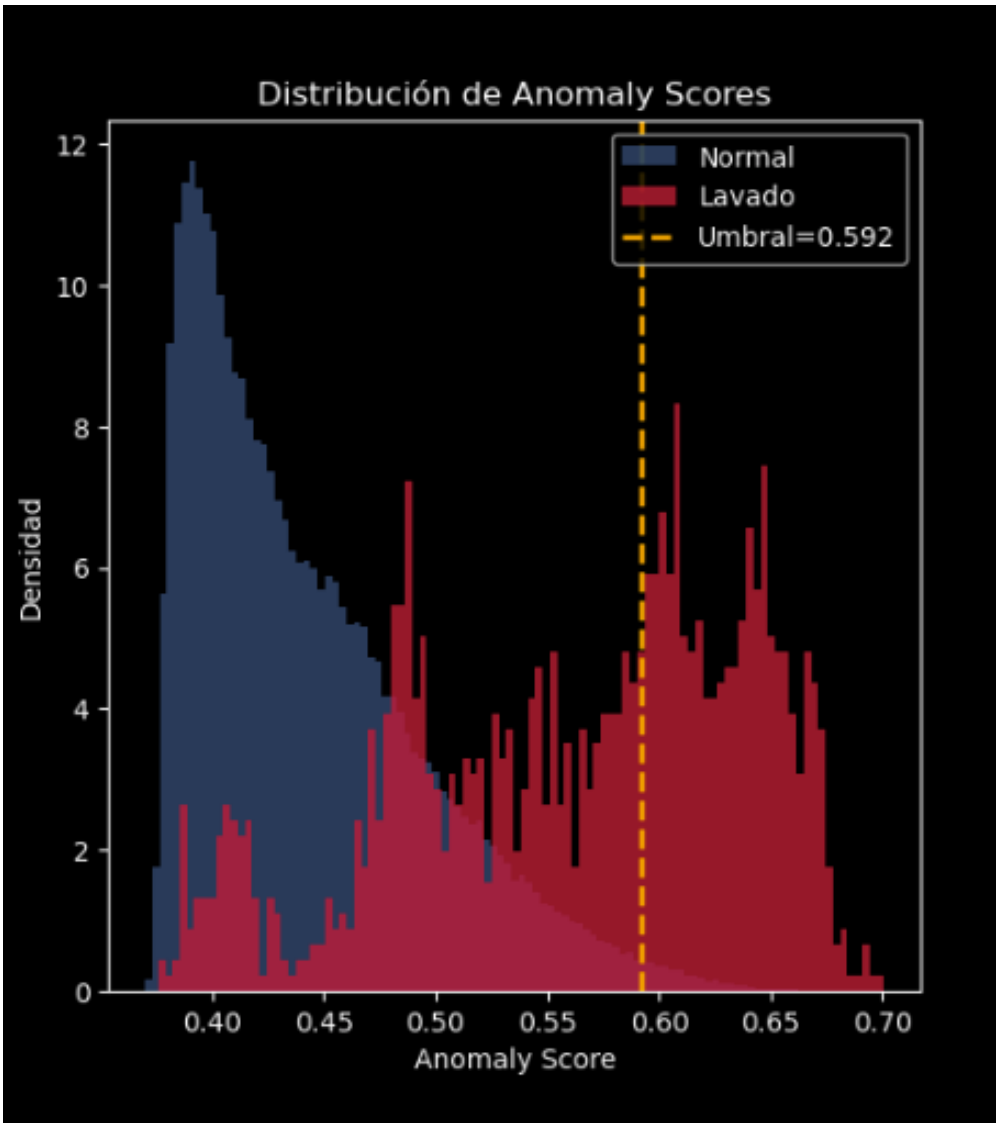


Figura 5-1: Distribución de scores de anomalía.

La curva ROC, presentada en la Figura **5-2**, complementa esta visualización al mostrar el comportamiento conjunto de la tasa de verdaderos positivos y la tasa de falsos positivos a lo largo de todos los umbrales posibles. El área bajo la curva, de 0.8864, se traduce gráficamente en el alejamiento sostenido de la curva respecto a la diagonal del clasificador aleatorio, con un punto Youden óptimo situado en la región de bajo FPR y alto TPR.

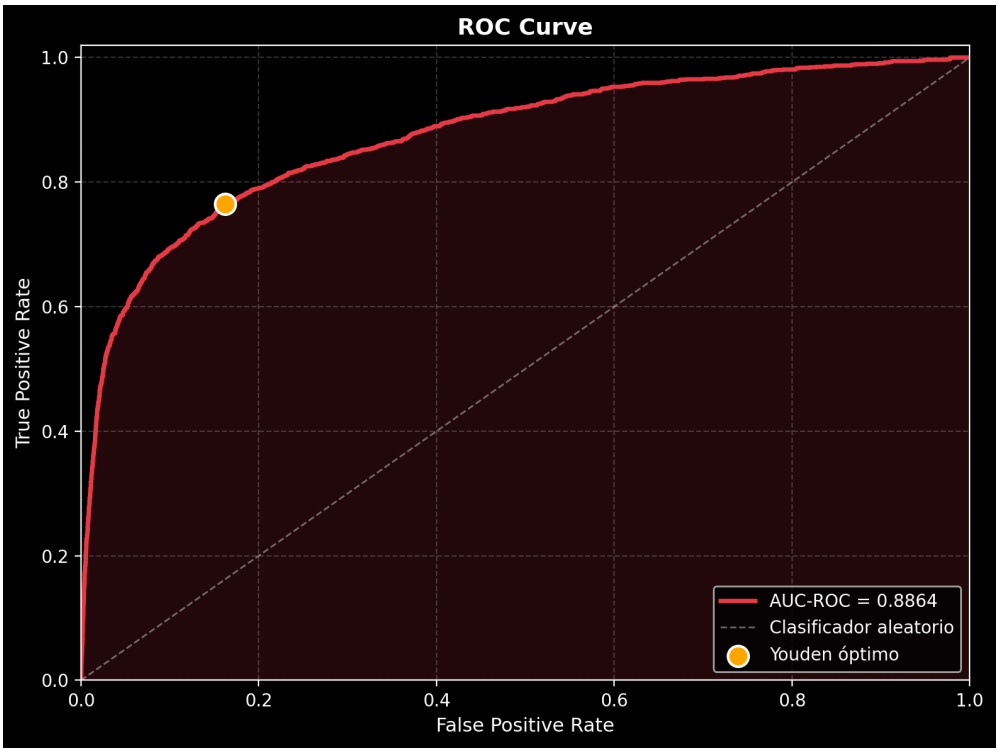


Figura 5-2: Curva ROC del modelo *Isolation Forest* sobre transacciones *Cash Deposit*. La marca naranja señala el punto óptimo según el índice de Youden.

Precisión en detección de eventos raros: AUPRC

En presencia de un desequilibrio de clases severo, en el cual las transacciones de lavado representan únicamente el 0.62 % del total, el $AUC\text{-}ROC$ puede resultar una métrica insuficiente por sí sola, dado que su cálculo integra el rendimiento del clasificador sobre ambas clases de manera simétrica *Davis & Goadrich* [2006]. La curva *Precision-Recall* y su área bajo la curva ($AUPRC$) constituyen en este contexto la métrica más informativa, al centrarse exclusivamente en el comportamiento del modelo sobre la clase positiva minoritaria *Saito & Rehmsmeier* [2015].

El modelo obtuvo un $AUPRC$ de 0.2653. Para interpretar correctamente este valor, es necesario compararlo contra el baseline de referencia adecuado que corresponde a un clasificador aleatorio, el cual obtendría un $AUPRC$ equivalente a la tasa de prevalencia de la clase positiva, es decir $\pi \approx 0{,}0062$ en el presente dataset *Davis & Goadrich* [2006]. El modelo propuesto supera dicho baseline en un factor de **42.5 veces**, lo que constituye evidencia de capacidad discriminativa real y estadísticamente significativa sobre la clase de interés.

Esta comparación contra el baseline aleatorio, cuyo AUPRC esperado es igual a la prevalencia de la clase positiva, $\pi \approx 0{,}0062$, no es meramente teórica, de hecho, en la práctica, los sistemas de monitoreo basados en reglas estáticas operan como clasificadores de umbral fijo que no aprenden la estructura discriminativa de los datos, sino que disparan alertas cuando se satisfacen condiciones predeterminadas sin capacidad de ordenar las transacciones por su grado de sospecha. Dado que estos sistemas no producen un *ranking* informado de anomalía, su capacidad para concentrar verdaderos positivos en las posiciones más altas del ordenamiento es, en términos estadísticos, comparable a la de un clasificador aleatorio que opera sobre la misma tasa de prevalencia. El lift de 42.5 veces refleja, por tanto, la ganancia concreta que aporta un modelo capaz de asignar puntuaciones de anomalía con poder discriminativo real.

La curva *Precision-Recall* presentada en la Figura **5-3** ilustra este comportamiento, en la gráfica se observa que el área sombreada bajo la curva contrasta marcadamente con la línea de baseline, particularmente en los rangos de recall bajo y medio donde el modelo mantiene niveles de precision elevados, lo que implica que los scores más altos del modelo están fuertemente asociados a transacciones genuinamente sospechosas.

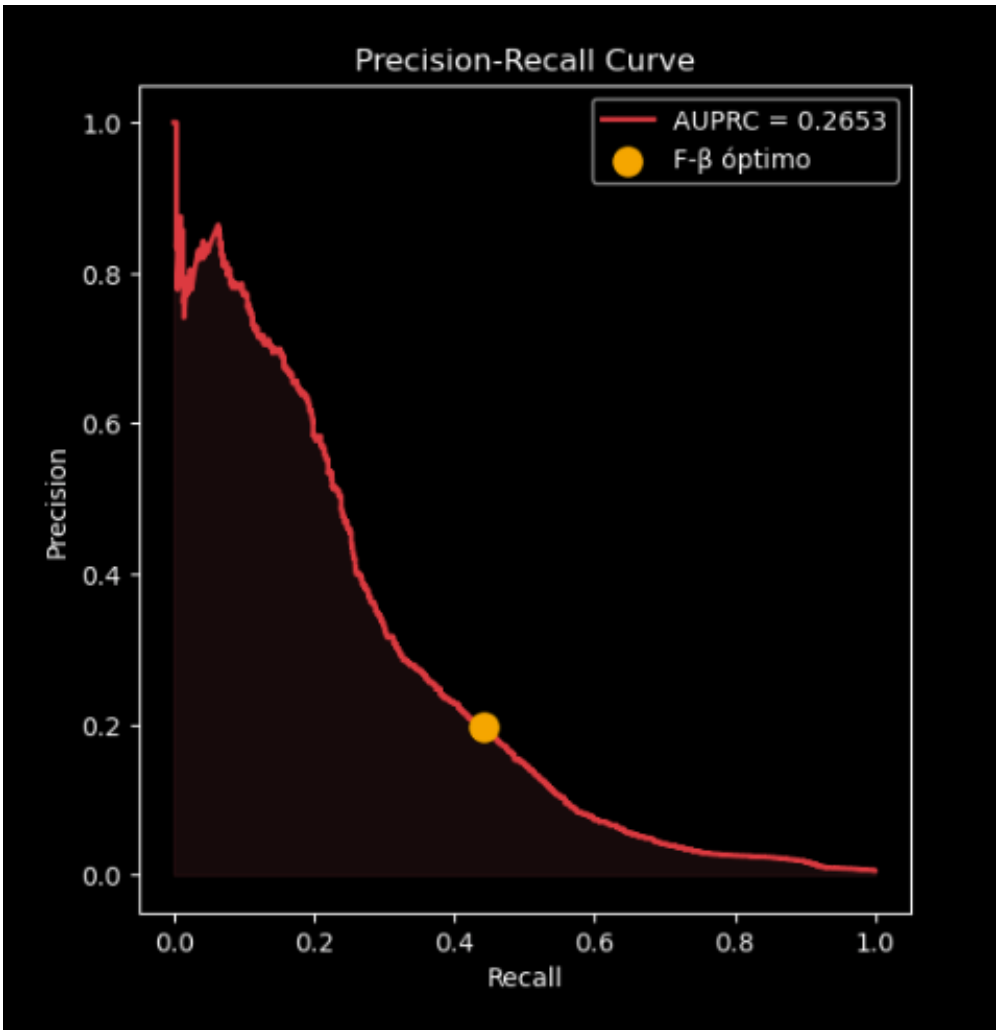


Figura 5-3: Curva Precision-Recall.

Selección del umbral de decisión

La conversión del *anomaly score* continuo en una predicción binaria requiere la definición de un umbral de clasificación cuya elección determina el balance entre la tasa de detección (*recall*) y la tasa de falsas alarmas (*1 - precision*). En el presente estudio se evaluaron cuatro criterios alternativos de selección de umbral, cuyos resultados se presentan en la Tabla **5-2**.

Tabla 5-2: Comparación de criterios de selección de umbral

Método	Umbral	Precision	Recall	F1	Alertas
F-β β=2 (seleccionado)	0.5923	0.1973	0.4427	0.2730	3,152
F1 óptimo	0.6270	0.4602	0.2512	0.3250	767
Youden Index	0.4794	0.0235	0.8534	0.0457	51,078
Percentil 98 %	0.5810	0.1532	0.4911	0.2335	4,505

El comportamiento del criterio F-β a lo largo del rango de umbrales posibles se ilustra en la Figura **5-4**. La curva exhibe una forma unimodal característica, con un máximo localizado en el umbral $\delta^* = 0{,}5923$ que constituye el punto de equilibrio óptimo entre detección y precisión bajo la ponderación impuesta por

$\beta = 2$. Umbrales por debajo de este valor incrementan el recall pero deterioran rápidamente la precisión por la incorporación de un volumen creciente de falsos positivos, mientras que umbrales superiores reducen el número de alertas a costa de pérdida en la capacidad de detección.

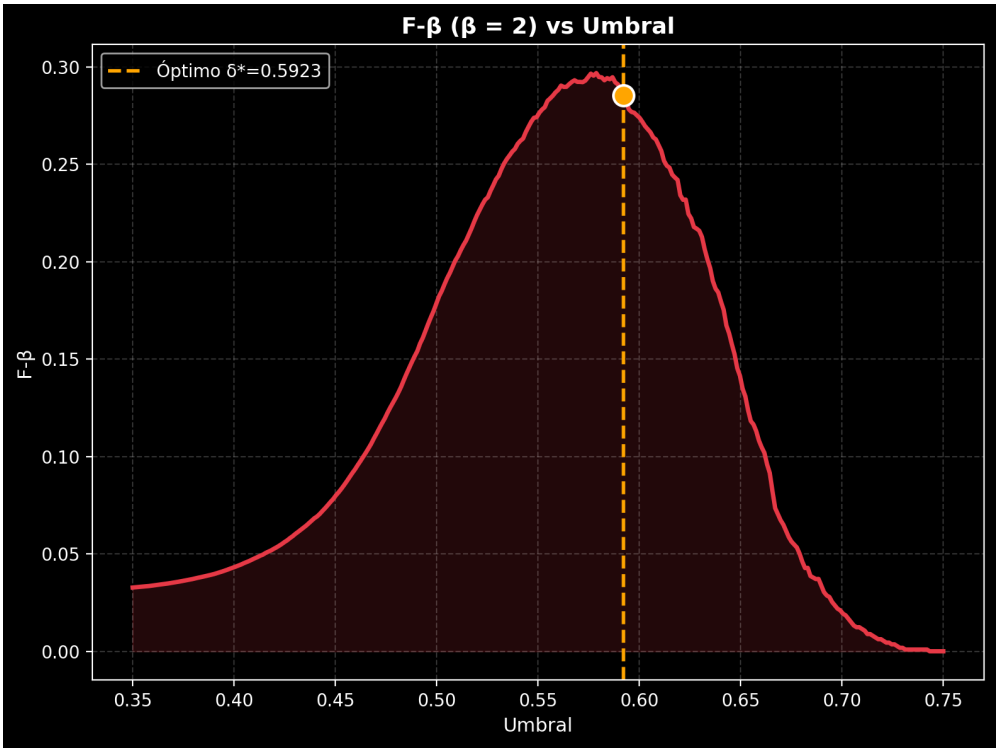


Figura 5-4: Evolución de la métrica F-β ($\beta = 2$) en función del umbral de clasificación. La línea naranja marca el umbral seleccionado $\delta^* = 0{,}5923$ que maximiza la métrica.

De forma complementaria, la Figura **5-5** descompone el trade-off entre precisión y recall en función del umbral, evidenciando la dinámica asimétrica de ambas métricas. Mientras el recall decrece monotónicamente al elevar el umbral, la precisión exhibe un crecimiento más gradual y con mayor variabilidad debido al efecto del extremo desbalance de clases. El umbral seleccionado se sitúa en la región donde la pendiente de pérdida de recall comienza a acentuarse, lo que justifica operacionalmente la decisión de no incrementarlo adicionalmente.

Como se explicó en el capítulo anterior, la selección del umbral óptimo bajo el criterio F-β con $\beta = 2$ responde a la estructura de costos asimétrica inherente al problema de detección de lavado de activos. La métrica F-β generaliza el F1-score asignando un peso β^2 veces mayor al *recall* respecto a la *precision*, de acuerdo con la expresión:

$$F_\beta = \frac{(1+\beta^2) \cdot \text{Precision} \cdot \text{Recall}}{\beta^2 \cdot \text{Precision} + \text{Recall}} \tag{5-1}$$

Con $\beta = 2$, los falsos negativos (transacciones de lavado no detectadas) reciben una penalización cuatro veces superior a la de los falsos positivos. Esta parametrización está fundamentada en la asimetría real de consecuencias que puede tener un falso negativo, dado que este implica que una operación ilícita atraviesa el sistema sin ser detectada, con las consiguientes implicaciones de incumplimiento regulatorio, riesgo reputacional y potencial responsabilidad legal del oficial de cumplimiento *Financial Action Task Force* [2023]. Un falso positivo, en contraste, se traduce únicamente en el costo operacional de investigar una transacción legítima, lo cual es un costo acotado y previsible *Levi & Reuter* [2018].

Es importante destacar que, si bien el umbral F1 óptimo produce un F1-score superior (0.3250 frente a 0.2730), lo hace a costa de reducir el *recall* a 0.2512, lo que significa que aproximadamente tres de

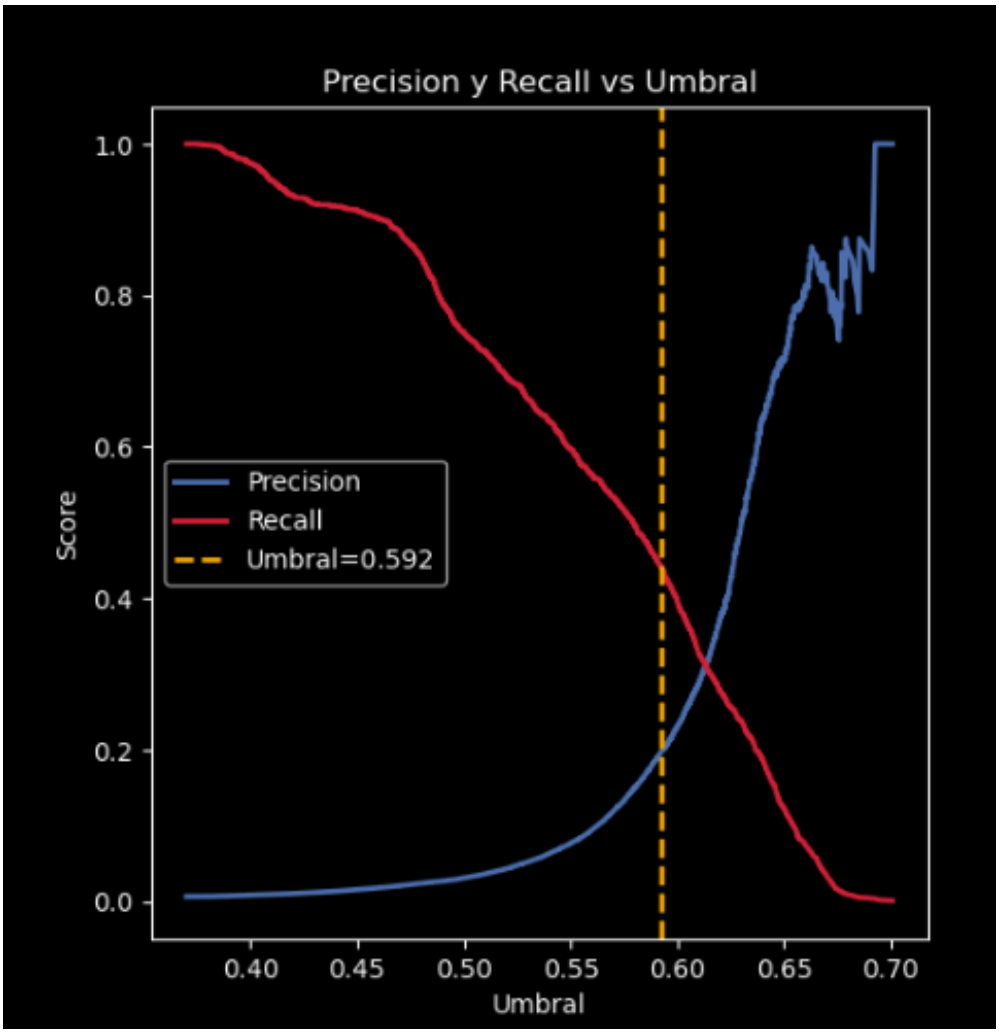


Figura 5-5: *Precision* y *recall* como función del umbral de clasificación. La línea naranja indica el umbral seleccionado por el criterio F-β.

cada cuatro operaciones de lavado no serían detectadas. Desde la perspectiva del cumplimiento normativo, optimizar F1 en este contexto constituiría una decisión metodológicamente incorrecta, ya que implica asumir implícitamente que ambos tipos de error tienen el mismo costo, supuesto que contradice la normativa AML vigente *Basel Committee on Banking Supervision* [2005]. El umbral F-β con $\beta = 2$, al alcanzar un *recall* de 0.4427 generando 3,152 alertas, representa el balance óptimo entre capacidad de detección y viabilidad operacional del equipo de cumplimiento.

Análisis de la matriz de confusión

Con el umbral seleccionado (0.5923), el modelo produce los resultados de clasificación presentados en la Tabla **5-3** y visualizados en la Figura **5-6**.

El modelo detecta 622 de las 1,405 transacciones de lavado presentes en el dataset, correspondiente a un *recall* del 44.27 %. Los 783 casos no detectados (falsos negativos) representan transacciones de lavado cuyo *anomaly score* se encuentra por debajo del umbral seleccionado, lo que sugiere que exhiben patrones transaccionales más cercanos al comportamiento de la clase normal, posiblemente correspondiendo a tipologías de lavado más sofisticadas o con menor expresión en las *features* construidas.

Las 2,530 falsas alarmas generadas representan el 1.13 % de las transacciones legítimas del dataset. Este

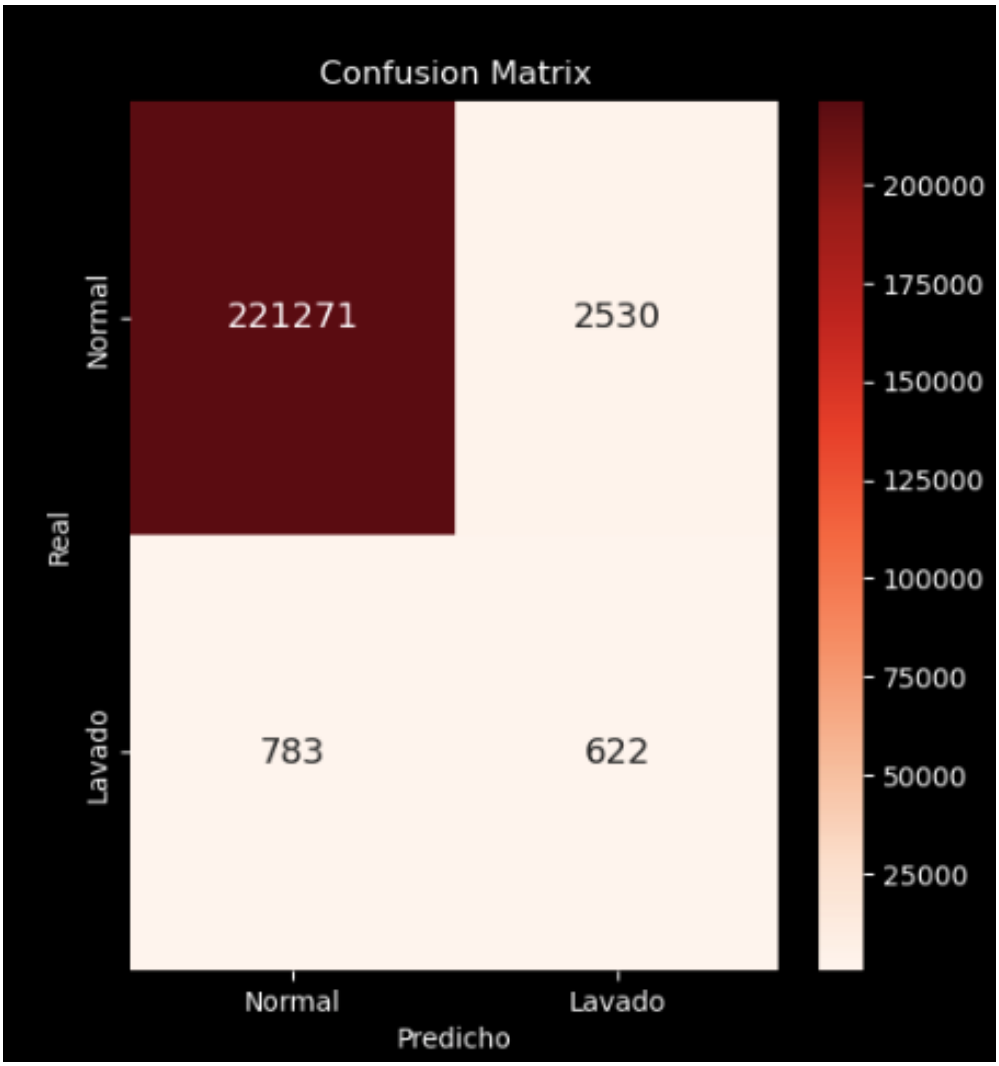


Figura 5-6: Matriz de confusión.

Tabla 5-3: Matriz de confusión — umbral F-β (β=2): 0.5923

		Predicción	
		Normal	**Lavado**
Real	Normal	221,271 (TN)	2,530 (FP)
	Lavado	783 (FN)	622 (TP)

valor debe ser contextualizado frente al desempeño de los sistemas de monitoreo de transacciones (*Transaction Monitoring Systems*, TMS) basados en reglas actualmente predominantes en la industria, cuyas tasas de falsa alarma se documentan en el rango del 90 % al 99 % del total de alertas generadas *Ferwerda* [2013]. La *precision* del 19.73 % alcanzada por el modelo propuesto implica que, de cada 10 alertas, aproximadamente 2 corresponden a lavado real, proporción que supera en al menos dos a cuatro veces la efectividad típica de los sistemas basados en reglas *Levi & Reuter* [2018], reduciendo significativamente la carga de investigación sobre los equipos de cumplimiento y mitigando el fenómeno de *alert fatigue* documentado como uno de los principales factores de ineficiencia operacional en los departamentos de cumplimiento AML *Ferwerda* [2013].

Validación temporal (*out-of-time*)

La validación temporal constituye el estándar metodológico más exigente para la evaluación de modelos predictivos en el dominio financiero, y su importancia radica en que reproduce con mayor fidelidad las condiciones reales de despliegue. El proceso consiste en que el modelo es entrenado sobre un período histórico y aplicado sobre observaciones futuras que no participaron en ninguna etapa del proceso de ajuste de parámetros *Hand* [2009]. Esta distinción es fundamental, ya que la evaluación sobre el mismo conjunto de entrenamiento, o incluso mediante validación cruzada estándar, puede subestimar la degradación del modelo ante la evolución temporal de los patrones transaccionales, fenómeno conocido como *concept drift Gama et al.* [2014].

En el presente estudio, la validación *out-of-time* fue implementada entrenando el modelo *Isolation Forest* exclusivamente sobre transacciones del año 2022 y evaluando su desempeño sobre las transacciones del año 2023, conjunto este último que el modelo nunca observó durante el entrenamiento. Es importante destacar que la implementación se realizó con un proceso de ingeniería de características anclado exclusivamente al conjunto de entrenamiento, de modo que las estadísticas globales utilizadas como *features* (*z-score* por cuenta, métricas de red, umbral de *hub* receptor) no incorporan información del período de evaluación. Este anclaje, metodológicamente más exigente que la validación transductiva, refleja con mayor fidelidad las condiciones reales de despliegue del sistema. Los resultados se presentan en la Tabla **5-4**.

Tabla 5-4: Resultados de la validación temporal *out-of-time*

Conjunto de evaluación	**AUC-ROC**	**AUPRC**	**Lift vs. baseline**
Dataset completo (2022--2023)	0.8864	0.2653	42.5×
Out-of-time (test 2023)	0.8398	0.1657	24.9×
Degradación absoluta	−0.0466	−0.0996	---
Degradación relativa	−5.26 %	−37.5 %	---

La degradación del *AUC-ROC* entre ambos conjuntos es de 0.0466 puntos porcentuales, equivalente a una reducción relativa del 5.26 %. En el contexto de los modelos predictivos sobre datos financieros, esta magnitud de degradación es consistente con un nivel moderado de *concept drift* inter-anual y se encuentra dentro de los rangos reportados por la literatura para sistemas de detección sobre datos transaccionales con horizontes temporales similares *Gama et al.* [2014].

La degradación del *AUPRC* (37.5 %) es proporcionalmente mucho mayor que la del *AUC-ROC*, lo cual es esperable y diagnósticamente informativo. El *AUC-ROC*, dominado estructuralmente por la separación de la clase mayoritaria, se mantiene relativamente estable, mientras que el *AUPRC*, métrica sensible a la posición de los positivos en el *ranking*, refleja con mayor fidelidad el efecto de la evolución temporal de las *features* sobre el desempeño en la clase minoritaria *Saito & Rehmsmeier* [2015]. El valor de 0.1657 obtenido en el conjunto *out-of-time* sigue representando una mejora de 24.9 veces sobre el clasificador aleatorio correspondiente a ese período, confirmando que la capacidad discriminativa del modelo se preserva en un horizonte temporal diferente al de entrenamiento y sigue siendo muy superior al baseline aleatorio que tienen los sistemas basados en reglas actuales.

Este resultado cobra especial relevancia en el contexto de los sistemas de detección de lavado de activos, donde los patrones de comportamiento ilícito evolucionan continuamente en respuesta a los controles implementados, fenómeno documentado por el *Financial Action Task Force* como adaptación táctica de las redes de lavado *Financial Action Task Force* [2023]. El hecho de que el modelo mantenga su poder discriminativo ante datos de un año posterior al de entrenamiento sugiere que las *features* construidas, particularmente las ventanas temporales rodantes, el *z-score* por cuenta y las métricas de red, capturan patrones estructurales del comportamiento anómalo que son razonablemente estables ante la evolución temporal moderada del período de calibración. Esta propiedad de generalización temporal representa una ventaja operacional concreta frente a los sistemas de monitoreo basados en reglas estáticas, cuya efectividad se deteriora rápidamente ante la evolución de las tipologías de lavado *Levi & Reuter* [2018].

En síntesis, la conjunción de un *AUC-ROC* de 0.84 con una mejora de 24.9 veces sobre el baseline aleatorio en el conjunto *out-of-time*, bajo un esquema de validación que evita explícitamente cualquier

fuga de información temporal, proporciona una base empírica sólida para sostener que el modelo *Isolation Forest* propuesto es estadísticamente válido, operacionalmente estable y metodológicamente riguroso para su aplicación en la detección de anomalías asociadas al lavado de activos en transacciones de tipo *Cash Deposit*.

5.2 Comparación contra Benchmarks

La evaluación comparativa del modelo *Isolation Forest* propuesto contra otros algoritmos no supervisados de detección de anomalías constituye un componente metodológico esencial para sustentar la elección algorítmica realizada en este trabajo. Para ello, se entrenaron y evaluaron dos benchmarks ampliamente referenciados en la literatura, *Local Outlier Factor* (LOF) y *Elliptic Envelope*, sobre el mismo conjunto de transacciones *Cash Deposit* y utilizando el mismo espacio de 46 características descrito en la Sección 3.3, garantizando así la comparabilidad directa de los resultados. Los hiperparámetros de los benchmarks se fijaron en valores estándar de la literatura ($k = 20$ vecinos para LOF, *support fraction* de 0.7 para *Elliptic Envelope*), y se utilizó la misma tasa de contaminación empírica derivada de la prevalencia observada de lavado. La Tabla **5-5** presenta los resultados obtenidos.

Tabla 5-5: Comparación contra benchmarks no supervisados sobre el mismo espacio de características

Modelo	AUC-ROC	AUPRC	Lift vs. baseline
Isolation Forest (propuesto)	**0.8864**	**0.2653**	**42.5×**
Local Outlier Factor ($k = 20$)	0.6384	0.0425	6.8×
Elliptic Envelope (sf=0.7)	0.8178	0.1676	26.9×

La comparación cuantitativa presentada en la Tabla **5-5** ofrece evidencia empírica directa sobre el desempeño relativo del modelo propuesto. En términos de *AUPRC*, métrica más adecuada para problemas de extremo desbalance, *Isolation Forest* (0.2653) supera a LOF (0.0425) por un factor de 6.2× y a *Elliptic Envelope* (0.1676) por un factor de 1.6×. El bajo desempeño relativo de LOF es consistente con la literatura que documenta su sensibilidad a la dimensionalidad y su degradación en espacios de alta dimensión como el utilizado en este trabajo, con 46 variables *Breunig et al.* [2000b]; *Chandola et al.* [2009]. Por su parte, el desempeño relativamente competitivo de *Elliptic Envelope*, a pesar de violar sus supuestos de normalidad multivariada dada la presencia de variables binarias, conteos y razones en el espacio de características, sugiere que parte significativa del poder discriminativo del sistema reside en la calidad del espacio de *features* construido. Este hallazgo refuerza la importancia metodológica del bloque de ingeniería de variables descrito en la Sección 3.3, indicando que el conocimiento experto codificado en las *features* de ventana deslizante, *z-score* por cuenta y análisis de red captura señales discriminativas robustas que son aprovechadas por múltiples familias de algoritmos no supervisados, pero que el mecanismo de aislamiento por particiones aleatorias del *Isolation Forest* explota de manera más efectiva.

Interpretación del AUPRC en escenarios de extremo desbalance de clases

La evaluación de modelos de detección de anomalías en el dominio financiero, y particularmente en relación con la detección de LA, presenta un desafío metodológico fundamental que es el severo desequilibrio entre las clases de interés. En el presente estudio, las transacciones de tipo *Cash Deposit* asociadas a lavado de activos representan únicamente el 0.62 % del total de observaciones, configurando lo que la literatura estadística denomina un problema de clasificación con *extreme class imbalance He & Garcia* [2009]. Bajo esta condición, el uso del *AUC-ROC* como única métrica de evaluación puede conducir a interpretaciones engañosas, dado que dicha métrica promedia el rendimiento del clasificador sobre todos los umbrales posibles y asigna un peso equivalente a ambas clases, favoreciendo sistemáticamente a la clase mayoritaria *Davis & Goadrich* [2006]. Esta limitación ha sido extensamente documentada, por ejemplo, *Saito & Rehmsmeier* [2015] demostraron formalmente que el *AUC-ROC* puede permanecer elevado incluso cuando el modelo tiene escasa utilidad práctica para detectar eventos raros, mientras que la curva *Precision-Recall* y su área bajo

la curva ($AUPRC$) reflejan con mayor fidelidad el comportamiento del clasificador sobre la clase positiva minoritaria.

Bajo este marco, el valor de referencia (*baseline*) para el $AUPRC$ no es 0.5, como lo sería para el $AUC\text{-}ROC$ bajo un clasificador aleatorio, sino que equivale exactamente a la prevalencia de la clase positiva en el conjunto de datos *Davis & Goadrich* [2006]. En el presente caso, dicho baseline corresponde a $\pi \approx 0{,}0062$. El modelo propuesto alcanza un $AUPRC$ de 0.2653 sobre el conjunto completo y de 0.1657 en la validación temporal *out-of-time*, lo que representa una mejora de **42.5 veces** y **24.9 veces** sobre el clasificador aleatorio, respectivamente. Esta métrica de *lift* relativo constituye la forma metodológicamente correcta de reportar el desempeño en escenarios desbalanceados *Flach & Kull* [2015], y es la que debe ser considerada como evidencia de la capacidad discriminativa real del modelo.

Adicionalmente, es necesario contextualizar estos resultados dentro del marco específico de la detección no supervisada de LA. A diferencia de los modelos supervisados, el *Isolation Forest* no recibe información sobre las etiquetas de clase durante el entrenamiento, lo que implica que el modelo infiere los patrones anómalos exclusivamente a partir de la estructura intrínseca de los datos. En este contexto, *Goldstein & Uchida* [2016] realizaron una evaluación comparativa de 19 algoritmos de detección de anomalías sobre múltiples conjuntos de datos reales con desequilibrio de clases, y reportaron que el *Isolation Forest* obtuvo consistentemente resultados superiores al resto de métodos no supervisados, con valores de $AUPRC$ en el rango 0.15-0.35 para datasets con tasas de anomalía inferiores al 1 %. El valor obtenido en el presente modelo (0.2653) se sitúa en la mitad superior de dicho rango, lo que respalda su calidad relativa dentro del estado del arte en detección no supervisada y resulta consistente con los resultados de la comparación directa contra LOF y *Elliptic Envelope* presentada en la Tabla **5-5**.

Desde la perspectiva operacional del cumplimiento normativo en materia de prevención de lavado de activos, la *precision* del 19.73 % alcanzada con el umbral F-beta ($\beta = 2$) debe interpretarse también en su contexto, que podría explicarse como que, de cada 100 alertas generadas, aproximadamente 20 corresponden a transacciones efectivamente vinculadas a lavado de activos. Si bien este valor puede parecer reducido en términos absolutos, la literatura en sistemas de monitoreo de transacciones (*Transaction Monitoring Systems*, TMS) reporta que los sistemas basados en reglas desplegados actualmente en la industria bancaria exhiben tasas de *precision* que oscilan entre el 1 % y el 10 % *Ferwerda* [2013]; *Levi & Reuter* [2018], generando una proporción abrumadora de falsas alarmas que sobrecarga a los equipos de cumplimiento y erosiona la efectividad operacional. En este sentido, el modelo propuesto duplica o cuadruplica la *precision* típica de los sistemas basados en reglas, con la ventaja adicional de ser auto-adaptativo y no requerir actualización manual de umbrales.

6 Discusión de resultados

Los resultados obtenidos en el presente estudio permiten articular una discusión en torno a cuatro ejes principales: (i) la contribución de la ingeniería de características al poder discriminativo del modelo, (ii) la viabilidad operacional del sistema propuesto en el contexto de los equipos de cumplimiento, (iii) las limitaciones metodológicas y sus implicaciones para la interpretación de los hallazgos, y (iv) las líneas de trabajo futuro que se derivan de las oportunidades identificadas.

6.1 Contribución de la ingeniería de características

Uno de los hallazgos más relevantes del presente trabajo es que la capacidad discriminativa del modelo Isolation Forest, medida tanto por el AUC-ROC de 0.8864 como por un AUPRC 42.5 veces superior al baseline aleatorio, descansa en gran medida sobre la calidad del espacio de características construido, más que sobre la sofisticación algorítmica del método de detección en sí mismo. Isolation Forest es, por diseño, un algoritmo agnóstico a la semántica de las variables debido a que su mecanismo de partición aleatoria no incorpora conocimiento del dominio ni relaciones de causalidad entre atributos *Liu et al.* [2008]. En consecuencia, la responsabilidad de codificar el conocimiento experto sobre las tipologías de lavado de activos recae enteramente sobre el proceso de ingeniería de características.

El diseño de la función `build_features()`, organizada en seis bloques temáticos que cubren desde el contexto geopolítico y monetario hasta la estructura relacional del grafo transaccional, responde a una premisa central y es que las transacciones asociadas al lavado de activos no son necesariamente atípicas en cada dimensión individual, sino que su anomalía se manifiesta en la *combinación* de atributos que exhiben simultáneamente *Chandola et al.* [2009]; *Chen et al.* [2018]. Las variables de ventana deslizante, por ejemplo, transforman el problema de una detección puntual a una detección contextualmente informada, permitiendo que el modelo capture patrones de acumulación, aceleración y concentración temporal que son invisibles desde el análisis de transacciones aisladas. De forma análoga, las métricas de red (grado de salida del emisor, grado de entrada del receptor, concentración de contraparte y desequilibrio de flujo) introducen información relacional que los sistemas basados en reglas típicamente ignoran al operar sobre transacciones individuales *Barabási* [2016].

Esta observación tiene una implicación práctica directa y es que, en escenarios donde las instituciones financieras dispongan de datos transaccionales más ricos, por ejemplo, con información sobre el propósito declarado de la transacción, el perfil de actividad económica del cliente o el historial de alertas previas, la incorporación de dichas variables al espacio de características podría incrementar sustancialmente el poder discriminativo del modelo sin requerir modificaciones al algoritmo subyacente.

6.2 Viabilidad operacional y comparación con sistemas basados en reglas

El segundo eje de discusión se centra en la viabilidad del modelo como componente de un sistema de monitoreo transaccional operacional. La evaluación presentada en el Capítulo 5 muestra que, con el umbral $\delta^* = 0{,}5923$ derivado del criterio F_β con $\beta = 2$, el modelo genera 3,152 alertas sobre un conjunto de 225,206

transacciones de tipo *Cash Deposit*, lo que equivale a una tasa de alertamiento del 1.40 %. De estas alertas, 622 corresponden a transacciones efectivamente asociadas a lavado de activos (precision = 0.1973), lo que implica que aproximadamente una de cada cinco alertas generadas es un verdadero positivo.

Este resultado debe contextualizarse frente a la realidad operativa de los sistemas de monitoreo transaccional (TMS) basados en reglas que predominan en la industria financiera. La literatura documenta de manera consistente que dichos sistemas exhiben tasas de falsos positivos superiores al 90 %, con algunos estudios reportando valores que alcanzan el 95 %-99 % del total de alertas generadas *Bakry et al.* [2024]; *Oztas et al.* [2024]. En términos de precision, esto equivale a valores del 1 % al 10 %, rango en el que la gran mayoría de las alertas investigadas por los equipos de cumplimiento resultan ser transacciones legítimas que no ameritaban revisión *Levi & Reuter* [2018]. El modelo propuesto, con una precision del 19.73 %, duplica o cuadruplica la efectividad típica de estos sistemas, lo que se traduce en una reducción proporcional del esfuerzo investigativo desperdiciado y una mitigación del fenómeno de *alert fatigue* que se entiende como la desensibilización progresiva de los analistas ante volúmenes abrumadores de falsas alarmas, documentado como uno de los principales factores de degradación operacional en los departamentos de cumplimiento AML *Ferwerda* [2013].

No obstante, es necesario señalar que el recall del 44.27 % implica que más de la mitad de las transacciones de lavado presentes en el dataset no son detectadas por el modelo con el umbral seleccionado. Si bien este nivel de detección es sustancialmente superior al que ofrecería un clasificador aleatorio, y comparable con los rangos reportados en la literatura para modelos no supervisados en dominios financieros *Ahmed et al.* [2016]; *Goldstein & Uchida* [2016], dista de ser suficiente como mecanismo único de detección. Esta observación refuerza la posición adoptada en la literatura especializada según la cual los modelos de aprendizaje automático no deben concebirse como reemplazos de los sistemas basados en reglas, sino como *capas complementarias* que operan en paralelo, donde el modelo de anomalías captura patrones que las reglas estáticas no pueden detectar, y las reglas cubren tipologías conocidas para las cuales existen umbrales regulatorios explícitos *Chen et al.* [2018]; *Oztas et al.* [2024].

6.3 Estabilidad temporal y generalización

La validación out-of-time, implementada mediante el entrenamiento del modelo sobre transacciones de 2022 y su evaluación sobre datos de 2023, constituye uno de los resultados metodológicamente más exigentes del presente estudio. El proceso de ingeniería de características fue anclado exclusivamente al período de entrenamiento, de modo que las estadísticas globales (z-score por cuenta, métricas de red, umbral de hub receptor) no incorporan información del año 2023, garantizando la ausencia de fuga de información temporal. Bajo este esquema, la degradación del AUC-ROC del 5.26 % y del AUPRC del 37.5 % proporciona una caracterización honesta del comportamiento del modelo ante concept drift inter-anual. La asimetría entre ambas métricas es diagnósticamente informativa: el AUC-ROC, dominado estructuralmente por la masa de verdaderos negativos en problemas con extremo desbalance, exhibe degradación moderada; el AUPRC, métrica sensible a la posición relativa de los positivos en el ranking, refleja con mayor fidelidad el efecto del drift sobre la clase minoritaria. A pesar de esta degradación, el modelo retiene un lift de 24.9 veces sobre el baseline aleatorio en el conjunto OOT, lo que confirma que las features construidas capturan patrones estructurales del comportamiento anómalo que son robustos a la evolución temporal moderada de las distribuciones subyacentes.

Este resultado cobra especial relevancia a la luz del fenómeno de *concept drift*, la evolución temporal de las distribuciones subyacentes de los datos, que representa uno de los principales desafíos operativos de los modelos predictivos en el dominio financiero *Gama et al.* [2014]. El hecho de que el modelo preserve su capacidad discriminativa ante datos de un año posterior al de entrenamiento sugiere que las variables de ventana deslizante, el z-score por cuenta y las métricas de red codifican señales de anomalía que son razonablemente estables ante cambios moderados en los patrones transaccionales. Sin embargo, es razonable esperar que, a medida que el horizonte temporal de aplicación se extienda más allá del período evaluado, la degradación del desempeño se acentúe, particularmente si las tipologías de lavado evolucionan significativamente en respuesta a los controles implementados, fenómeno que el GAFI ha documentado como adaptación táctica de las redes de lavado *Financial Action Task Force* [2023].

6.4 Limitaciones del estudio

El presente trabajo presenta limitaciones que deben ser explicitadas para una interpretación rigurosa de los resultados las cuales se listan a continuación:

- **Uso de datos sintéticos.** La principal limitación del estudio radica en la utilización del conjunto de datos sintético SAML-D como base para el entrenamiento y evaluación del modelo. Si bien SAML-D fue diseñado con alto grado de realismo, incorporando múltiples tipologías transaccionales, canales de pago, monedas y estructuras de red *Oztas et al.* [2023], los datos sintéticos no pueden reproducir plenamente la complejidad, el ruido y las idiosincrasias de las transacciones financieras reales. En particular, los patrones de comportamiento de los clientes legítimos en datos sintéticos pueden ser más regulares y predecibles que en la realidad, lo que podría sobreestimar la capacidad del modelo para distinguir entre transacciones normales y sospechosas. La transferibilidad de los resultados a entornos de producción con datos reales no puede garantizarse sin una validación adicional sobre datos institucionales.

- **Alcance limitado a un tipo transaccional.** El modelo fue entrenado y evaluado exclusivamente sobre transacciones de tipo *Cash Deposit*. Si bien esta decisión permite un análisis focalizado y controla la heterogeneidad del espacio de características, también restringe la generalización de los hallazgos a otros canales transaccionales, tales como transferencias electrónicas, pagos con tarjeta, cheques o transacciones transfronterizas, que poseen dinámicas de comportamiento y tipologías de lavado distintas *Financial Action Task Force* [2006]. Un sistema de monitoreo transaccional completo requeriría modelos específicos o un modelo unificado capaz de operar sobre múltiples canales simultáneamente.

- **Configuración transductiva.** Como se señaló en la Sección 4.2, el modelo fue ajustado e inferido sobre el mismo conjunto de datos (*transductive setting*), una práctica habitual en detección de anomalías no supervisada pero que impide la estimación estricta del error de generalización. Aunque la validación *out-of-time* mitiga parcialmente esta limitación al evaluar sobre un período temporal no observado durante el entrenamiento, la ausencia de una partición *train/test* convencional en la evaluación sobre el dataset completo debe considerarse al interpretar las métricas reportadas en la Tabla 5-1.

- **Ausencia de explicabilidad a nivel de transacción individual.** Isolation Forest produce una puntuación de anomalía global para cada transacción, pero no identifica de forma nativa cuáles son las variables que más contribuyen a dicha puntuación en cada caso particular. Si bien la estructura del árbol de aislamiento permite, en principio, el análisis de las particiones que conducen al aislamiento de una observación, la implementación actual no incorpora mecanismos formales de explicabilidad como SHAP (*SHapley Additive exPlanations*) o análisis de importancia de variables por permutación. Esta limitación es relevante desde la perspectiva regulatoria, dado que los marcos normativos de múltiples jurisdicciones exigen que las instituciones financieras puedan justificar las razones por las cuales una transacción fue marcada como sospechosa *Financial Action Task Force* [2012 2023]. La incorporación de técnicas de explicabilidad constituye una línea de trabajo futuro prioritaria.

- **Parámetro de contaminación estimado a partir de etiquetas.** La estimación del parámetro de contaminación $\hat{\rho}$ a partir de la prevalencia empírica de lavado en el conjunto etiquetado (ecuación 4-2) introduce una dependencia implícita con la información supervisada que, si bien no interviene en el ajuste del modelo, condiciona el umbral de decisión por defecto. En un escenario de despliegue real donde las etiquetas no estén disponibles, la estimación de $\hat{\rho}$ requeriría métodos alternativos, como la calibración basada en la capacidad operativa del equipo de cumplimiento o la estimación robusta de la tasa de contaminación mediante técnicas estadísticas no supervisadas.

Líneas de trabajo futuro

Los resultados y limitaciones discutidos sugieren múltiples direcciones para la extensión del presente trabajo.

En primer lugar, la **validación sobre datos reales** constituye el paso natural e imprescindible para confirmar la transferibilidad de los hallazgos. La colaboración con instituciones financieras que dispongan de

conjuntos de datos transaccionales etiquetados (o, al menos, parcialmente etiquetados) permitiría evaluar el desempeño del modelo en condiciones operacionales reales y ajustar la ingeniería de características a las particularidades de cada entorno.

En segundo lugar, la **extensión a múltiples canales transaccionales**, incluyendo transferencias electrónicas, pagos con tarjeta y operaciones transfronterizas, ampliaría la cobertura del sistema y permitiría la construcción de un modelo unificado o de un ensamble de modelos especializados por canal.

En tercer lugar, la incorporación de **técnicas de explicabilidad**, tales como SHAP *Kou et al.* [2021] o LIME, a nivel de transacción individual, permitiría generar narrativas automáticas de las razones de alerta, facilitando el trabajo investigativo de los analistas de cumplimiento y satisfaciendo los requerimientos regulatorios de trazabilidad de las decisiones.

En cuarto lugar, la exploración de **extensiones del algoritmo**, como *Extended Isolation Forest Hariri et al.* [2019], que introduce hiperplanos oblicuos en lugar de particiones alineadas a los ejes, o la combinación con técnicas semi-supervisadas que aprovechen las etiquetas parciales disponibles en escenarios reales, podría incrementar la capacidad del modelo para capturar anomalías locales y fronteras de decisión más complejas.

Finalmente, el diseño de un **marco de monitoreo continuo** que incorpore mecanismos de detección de *concept drift Gama et al.* [2014] y reentrenamiento periódico del modelo garantizaría la estabilidad del desempeño a lo largo del tiempo, atendiendo la naturaleza dinámica de las tipologías de lavado de activos y la evolución de los patrones transaccionales legítimos.

7 Conclusiones

El presente trabajo tuvo como objetivo general desarrollar un modelo de aprendizaje automático no supervisado para la detección de anomalías asociadas al lavado de activos basado en el algoritmo Isolation Forest, utilizando como base el conjunto de datos sintético SAML-D. A partir de los tres objetivos específicos planteados, los resultados obtenidos permiten formular las siguientes conclusiones.

Sobre la construcción del conjunto de datos de modelado: Se diseñó e implementó un pipeline de ingeniería de características que transforma las transacciones financieras en bruto en una representación de 46 variables numéricas organizadas en seis bloques temáticos (contexto geopolítico y monetario, comportamiento temporal, indicadores de estructuración, estadísticas de ventana deslizante, puntuación de anomalía por cuenta y métricas de análisis de red). La construcción deliberada de variables que amplifican las diferencias comportamentales entre transacciones legítimas y sospechosas, tales como la aceleración del volumen transaccional, el z-score por cuenta y la concentración de contraparte, resultó determinante para el desempeño del modelo, confirmando que, en el contexto de la detección no supervisada de anomalías, la calidad del espacio de características es al menos tan importante como la elección del algoritmo de detección.

Sobre la implementación del modelo Isolation Forest: El modelo fue implementado con una configuración de 500 árboles de aislamiento, submuestreo de 256 observaciones por árbol, fracción de subespacio del 80 % y muestreo bootstrap, siguiendo las recomendaciones del artículo original de Liu et al. *Liu et al.* [2008] y las extensiones propuestas en la literatura. La estimación empírica del parámetro de contaminación a partir de la prevalencia observada de lavado, junto con la evaluación sistemática de cuatro criterios de selección de umbral, condujo a la adopción del criterio F_β con $\beta = 2$ como regla de decisión operacional. Este criterio, al ponderar el recall cuatro veces más que la precision, formaliza la asimetría de costos inherente al problema de detección de lavado de activos, donde un falso negativo tiene consecuencias regulatorias, reputacionales y sociales significativamente mayores que un falso positivo.

Sobre la evaluación del desempeño del modelo. El modelo alcanzó un AUC-ROC de 0.8864 y un AUPRC de 0.2653, lo que representa una mejora de 42.5 veces sobre el clasificador aleatorio correspondiente a la prevalencia de la clase positiva ($\pi \approx 0{,}0062$). Con el umbral seleccionado ($\delta^* = 0{,}5923$), el sistema genera 3,152 alertas con un recall del 44.27 % y una precision del 19.73 %, duplicando o cuadruplicando la efectividad típica de los sistemas de monitoreo basados en reglas documentada en la literatura. La validación temporal *out-of-time* (entrenamiento sobre 2022, evaluación sobre 2023), implementada con un esquema metodológicamente riguroso que evita la fuga de información temporal, evidencia una degradación del AUC-ROC del 5.26 % y del AUPRC del 37.5 %, manteniendo no obstante un lift de 24.9 veces sobre el baseline aleatorio en el conjunto de prueba temporal. La asimetría observada entre ambas métricas es consistente con concept drift inter-anual moderado y refleja honestamente las condiciones esperables en un escenario de despliegue real.

Sobre la contribución al estado del arte. Los resultados del presente estudio se sitúan dentro de la mitad superior del rango de AUPRC reportado por Goldstein & Uchida *Goldstein & Uchida* [2016] para algoritmos no supervisados en datasets con tasas de anomalía inferiores al 1 %, y son consistentes con los valores de AUC-ROC obtenidos por Puech et al. *Puech et al.* [2019] al aplicar Isolation Forest sobre datos bancarios reales. La contribución diferencial de este trabajo radica en la integración de un pipeline completo que va desde la ingeniería de características orientada al dominio AML hasta la evaluación con métricas apropiadas para problemas de extremo desbalance de clases, sobre un conjunto de datos sintético de alta complejidad, proporcionando un marco replicable y extensible para futuras investigaciones.

Sobre las implicaciones prácticas. Desde la perspectiva del cumplimiento normativo, los hallazgos

sugieren que los modelos de detección de anomalías basados en Isolation Forest constituyen una herramienta complementaria viable para los sistemas de monitoreo transaccional existentes. Su capacidad para identificar patrones atípicos sin requerir etiquetas de entrenamiento, su escalabilidad computacional a grandes volúmenes de transacciones y su estabilidad temporal ante la evolución de los datos los posicionan como un componente valioso de una arquitectura de cumplimiento que integre reglas estáticas y modelos adaptativos. No obstante, las limitaciones asociadas al uso de datos sintéticos, al alcance restringido a un único canal transaccional y a la ausencia de mecanismos formales de explicabilidad deben ser atendidas antes de considerar un despliegue en entorno de producción.

En síntesis, el presente trabajo demuestra que es factible construir un sistema de detección de anomalías asociadas al lavado de activos mediante técnicas de aprendizaje automático no supervisado que ofrezca un desempeño competitivo con el estado del arte, bajo un marco metodológico riguroso y con resultados que exhiben estabilidad temporal. Las líneas de trabajo futuro identificadas (validación sobre datos reales, extensión multicanal, incorporación de explicabilidad, exploración de variantes algorítmicas y diseño de un marco de monitoreo continuo) constituyen pasos naturales hacia la maduración de esta aproximación para su adopción en entornos institucionales de cumplimiento en instituciones financieras.

8 Anexos

Este capítulo recoge los recursos complementarios al cuerpo principal del trabajo. Se proporciona la referencia al repositorio público donde residen los notebooks de análisis exploratorio, el módulo de ingeniería de características y el código de entrenamiento y evaluación del modelo *Isolation Forest*, de manera que cualquier interesado pueda reproducir los experimentos descritos en los capítulos anteriores o extenderlos a otros conjuntos de datos transaccionales.

8.1 Repositorio de Código

Los notebooks y el código fuente asociados a este proyecto se encuentran disponibles públicamente en el siguiente repositorio de GitLab: `https://gitlab.com/dovallec/iforest_aml_detection`.

Referencias Bibliográficas

Ahmed, M.; **Mahmood, A. N.** & **Islam, M. R.**: , 2016; A survey of anomaly detection techniques in financial domain; *Future Generation Computer Systems*; **55**: 278--288.

Bahnsen, A. C.; **Aouada, D.**; **Stojanovic, A.** & **Ottersten, B.**: , 2016; Feature engineering strategies for credit card fraud detection; *Expert Systems with Applications*; **51**: 134--142.

Bakry, A. N.; **Alsharkawy, A. S.**; **Farag, M. S.** & **Raslan, K. R.**: , 2024; Automatic suppression of false positive alerts in anti-money laundering systems using machine learning; *The Journal of Supercomputing*; **80** (5): 6264--6284.

Barabási, A.-L.: , 2016; *Network Science*; Cambridge University Press, Cambridge.

Basel Committee on Banking Supervision: , 2005; Studies on the validation of internal rating systems; *Informe Técnico 14*; Bank for International Settlements.

Board of Governors of the Federal Reserve System: , 2011; Supervisory guidance on model risk management; *Informe Técnico SR 11-7*; Federal Reserve.

Breiman, L.: , 2001; Random forests; *Machine Learning*; **45** (1): 5--32.

Breunig, M. M.; **Kriegel, H.-P.**; **Ng, R. T.** & **Sander, J.**: , 2000a; Lof: Identifying density-based local outliers; en *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*; págs. 93--104.

Breunig, M. M.; **Kriegel, H.-P.**; **Ng, R. T.** & **Sander, J.**: , 2000b; Lof: identifying density-based local outliers; *ACM SIGMOD Record*; **29** (2): 93--104.

Chandola, V.; **Banerjee, A.** & **Kumar, V.**: , 2009; Anomaly detection: A survey; *ACM Computing Surveys*; **41** (3): 1--58; doi:10.1145/1541880.1541882.

Chen, Z.; **Van Khoa, L. D.**; **Teoh, E. N.**; **Nazir, A.**; **Karuppiah, E. K.** & **Lam, K. S.**: , 2018; Machine learning techniques for anti-money laundering (aml) solutions in suspicious transaction detection: a review; *Knowledge and Information Systems*; **57** (2): 245--285; doi:10.1007/s10115-017-1144-z.

Dal Pozzolo, A.; **Caelen, O.**; **Le Borgne, Y.-A.**; **Waterschoot, S.** & **Bontempi, G.**: , 2014; Learned lessons in credit card fraud detection from a practitioner perspective; *Expert Systems with Applications*; **41** (10): 4915--4928.

Dal Pozzolo, A.; **Caelen, O.**; **Johnson, R. A.** & **Bontempi, G.**: , 2015; Calibrating probability with undersampling for unbalanced classification; en *2015 IEEE Symposium Series on Computational Intelligence*; IEEE; págs. 159--166.

Davis, J. & **Goadrich, M.**: , 2006; The relationship between precision-recall and roc curves; en *Proceedings of the 23rd international conference on Machine learning*; págs. 233--240.

Domingues, R.; **Filippone, M.**; **Michiardi, P.** & **Zouaoui, J.**: , 2018; A comparative evaluation of outlier detection algorithms: Experiments and analyses; *Pattern Recognition*; **74**: 406--421.

Ferwerda, J.: , 2013; *The European Fight against Money Laundering*; Edward Elgar Publishing.

FFIEC: , 2023a; Bsa/aml examination manual -- risks associated with money laundering: Cash-intensive businesses; URL `https://bsaaml.ffiec.gov/manual/RisksAssociatedWithMoneyLaunderingAndTerroristFinancing/26`; consultado: 2026-02-28.

FFIEC: , 2023b; Bsa/aml examination manual -- appendix f: Money laundering and terrorist financing red flags; URL `https://bsaaml.ffiec.gov/manual/Appendices/07`; consultado: 2026-02-28.

Financial Action Task Force: , 2006; Trade-based money laundering; *Informe técnico*; FATF/OECD; Paris.

Financial Action Task Force: , 2012; International standards on combating money laundering and the financing of terrorism & proliferation: The fatf recommendations; *Informe técnico*; FATF/OECD; Paris.

Financial Action Task Force: , 2018; Professional money laundering; *Informe técnico*; FATF/OECD; URL `https://www.fatf-gafi.org/content/dam/fatf-gafi/reports/Professional-Money-Laundering.pdf`.

Financial Action Task Force: , 2023; Methodology for assessing compliance with the fatf recommendations; *Informe técnico*; FATF/OECD.

Financial Action Task Force: , 2024; Frequently asked questions: Money laundering; URL `https://www.fatf-gafi.org/en/pages/frequently-asked-questions.html`; consultado: 2026-02-28.

Fiore, U.; **De Santis, A.**; **Perla, F.**; **Zanetti, P.** & **Palmieri, F.**: , 2019; Using generative adversarial networks for improving classification effectiveness in credit card fraud detection; *Information Sciences*; **479**: 448--455.

Flach, P. & **Kull, M.**: , 2015; Precision-recall-gain curves: Pr analysis done right; *Advances in Neural Information Processing Systems*; **28**.

Gama, J.; **Žliobaitė, I.**; **Bifet, A.**; **Pechenizkiy, M.** & **Bouchachia, A.**: , 2014; A survey on concept drift adaptation; *ACM Computing Surveys*; **46** (4): 1--37.

Ghevariya, R.; **Desai, R.**; **Bohara, M. H.** & **Garg, D.**: , 2021; Credit card fraud detection using local outlier factor & isolation forest algorithms: A complete analysis; en *2021 5th International Conference on Electronics, Communication and Aerospace Technology (ICECA)*; IEEE; págs. 1679--1685.

Goldstein, M. & **Uchida, S.**: , 2016; A comparative evaluation of unsupervised anomaly detection algorithms for multivariate data; *PLOS ONE*; **11** (4): e0152173.

Hand, D. J.: , 2009; Measuring classifier performance: a coherent alternative to the area under the roc curve; *Machine learning*; **77** (1): 103--123.

Hanley, J. A. & **McNeil, B. J.**: , 1982; The meaning and use of the area under a receiver operating characteristic (roc) curve; *Radiology*; **143** (1): 29--36.

Hariri, S.; **Kind, M. C.** & **Brunner, R. J.**: , 2019; Extended isolation forest; *IEEE transactions on knowledge and data engineering*; **33** (4): 1479--1489.

He, H. & **Garcia, E. A.**: , 2009; Learning from imbalanced data; *IEEE Transactions on Knowledge and Data Engineering*; **21** (9): 1263--1284.

Her Majesty's Government: , 2002; Proceeds of crime act 2002; UK Parliament; chapter 29.

Jurgovsky, J.; **Granitzer, M.**; **Ziegler, K.**; **Calabretto, S.**; **Portier, P.-E.**; **He-Guelton, L.** & **Caelen, O.**: , 2018; Sequence classification for credit-card fraud detection; *Expert Systems with Applications*; **100**: 234--245.

Kieu, T.; **Yang, B.**; **Guo, C.** & **Jensen, C. S.**: , 2019; Outlier detection for time series with recurrent autoencoder ensembles; en *Proceedings of the 28th International Joint Conference on Artificial Intelligence (IJCAI)*; págs. 2725--2732.

Kou, G.; **Xu, Y.**; **Peng, Y.**; **Shen, F.**; **Chen, Y.**; **Chang, K.** & **Kou, S.**: , 2021; Bankruptcy prediction for smes using transactional data and two-stage multiobjective feature selection; *Decision Support Systems*; **140**: 113429.

Kute, D. V.; **Pradhan, B.**; **Shukla, N.** & **Alamri, A.**: , 2021; Deep learning and explainable artificial intelligence techniques applied for detecting money laundering -- a critical review; *IEEE Access*; **9**: 82300--82317.

Levi, M. & **Reuter, P.**: , 2018; *Money Laundering and its Regulation*; SAGE Publications.

Liu, F. T.; **Ting, K. M.** & **Zhou, Z.-H.**: , 2008; Isolation forest; en *2008 Eighth IEEE International Conference on Data Mining*; IEEE; págs. 413--422; doi:10.1109/ICDM.2008.17.

Malhotra, P.; **Vig, L.**; **Shroff, G.** & **Agarwal, P.**: , 2015; Long short term memory networks for anomaly detection in time series; en *Proceedings of the European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning*; págs. 89--94.

Ngai, E. W. T.; **Hu, Y.**; **Wong, Y.**; **Chen, Y.** & **Sun, X.**: , 2011; The application of data mining techniques in financial fraud detection: A classification framework and an academic review of literature; *Decision Support Systems*; **50** (3): 559--569.

Oztas, B.; **Cetinkaya, D.**; **Adedoyin, F.**; **Budka, M.**; **Dogan, H.** & **Aksu, G.**: , 2023; Enhancing anti-money laundering: Development of a synthetic transaction monitoring dataset; en *2023 IEEE International Conference on e-Business Engineering (ICEBE)*; IEEE; págs. 47--54; doi:10.1109/ICEBE59045.2023.00028.

Oztas, B.; **Cetinkaya, D.**; **Adedoyin, F.**; **Budka, M.**; **Aksu, G.** & **Dogan, H.**: , 2024; Transaction monitoring in anti-money laundering: A qualitative analysis and points of view from industry; *Future Generation Computer Systems*; **159**: 161--171; doi:10.1016/j.future.2024.05.027.

Phua, C.; **Lee, V.**; **Smith-Miles, K.** & **Gayler, R.**: , 2010; A comprehensive survey of data mining-based fraud detection research; *arXiv preprint*.

Puech, T.; **Boussard, M.**; **D'Onofrio, A.** & **Tőrők, G.**: , 2019; Using autoencoders for anomaly detection and transfer learning in iot; *arXiv preprint arXiv:1907.11382*.

Rousseeuw, P. J. & **Van Driessen, K.**: , 1999; A fast algorithm for the minimum covariance determinant estimator; *Technometrics*; **41** (3): 212--223.

Saito, T. & **Rehmsmeier, M.**: , 2015; The precision-recall plot is more informative than the roc plot when evaluating binary classifiers on imbalanced datasets; *PLOS ONE*; **10** (3): e0118432.

Sanctions.io: , 2025; Understanding the 3 stages of money laundering: Placement, layering, and integration; URL `https://www.sanctions.io/blog/3-stages-of-money-laundering`.

Siddiqi, N.: , 2012; *Credit risk scorecards: developing and implementing intelligent credit scoring*; John Wiley & Sons.

Sirisha, A.; **Chaitanya, K.**; **Krishna, K. V. S. S. R.** & **Kanumalli, S. S.**: , 2021; Intrusion detection models using supervised and unsupervised algorithms -- a comparative estimation; *International Journal of Safety and Security Engineering*; **11** (1): 51--58.

Sumsub: , 2023; Kyc/aml regulations in colombia -- guide 2023; URL `https://sumsub.com/blog/aml-regulations-colombia/`.

Sun, J.; **Gu, L.** & **Chen, K.**: , 2020; An efficient alert aggregation method based on conditional rough entropy and knowledge granularity; *Entropy*; **22** (3): 324.

Superintendencia Financiera de Colombia: , 2016; Circular externa 055 de 2016 -- sarlaft; sistema de Administración del Riesgo de Lavado de Activos y de la Financiación del Terrorismo.

Teichmann, F. M.: , 2019; Recent trends in money laundering and terrorism financing; *Journal of Financial Regulation and Compliance*; **27** (1): 2--12.

United Nations Office on Drugs and Crime: , 2011; Estimating illicit financial flows resulting from drug trafficking and other transnational organized crimes; *UNODC*.

U.S. Department of the Treasury: , 2024; 2024 national money laundering risk assessment; *Informe técnico*; U.S. Department of the Treasury; URL `https://home.treasury.gov/system/files/136/2024-National-Money-Laundering-Risk-Assessment.pdf`.

Wang, H. & **Abraham, Z.**: , 2015; Concept drift detection for streaming data; *arXiv preprint arXiv:1504.01044*.

Youden, W. J.: , 1950; Index for rating diagnostic tests; *Cancer*; **3** (1): 32--35.