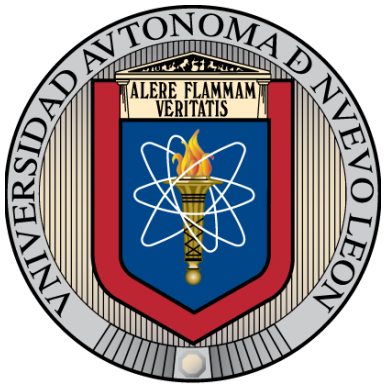
**UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN**

FACULTAD DE CIENCIAS FÍSICO MATEMÁTICAS




# (TÍTULO DEL TRABAJO DE INVESTIGACIÓN)

Por

GUSTAVO DE JESUS ESCOBAR MATA

Como requisito parcial para obtener el Grado de

MAESTRÍA EN CIENCIA DE DATOS

(Mes), (año)

Universidad Autónoma de Nuevo León

Facultad de Ciencias Físico Matemáticas

Los miembros del Comité de Tesis recomendamos que la Tesina “(título del trabajo de investigación)”, realizada por (el, la) alumno(a) (nombre completo del alumno, tipo oración, sin abreviaciones), con número de matrícula (matrícula), sea aceptada para su defensa como opción al grado de Maestría en Ciencia de Datos.

El Comité de Tesis

_____
(Título y nombre)
Director

_____
(Título y nombre)
Revisor

_____
(Título y nombre)
Revisor

Vo.Bo.

_____
Dra. Azucena Yoloxóchitl Ríos Mercado
Coordinadora de la Maestría en Ciencia de Datos

San Nicolás de los Garza, N.L.

## DEDICATORIA

*(Dedicatoria opcional justificada a la derecha en itálicas)*

## ÍNDICE DE CONTENIDO

Capítulo Página

1. INTRODUCCIÓN…….....1

1.1 (Subtítulo)……..……1
1.1.1 (Subtítulo)……1
1.2 (Subtítulo)……...1

2. DELIMITACIÓN Y PLANTEAMIENTO DEL PROBLEMA DE INVESTIGACIÓN.....2

3. JUSTIFICACIÓN…….....3

4. FORMULACIÓN DE OBJETIVOS……..……4

5. MARCO TEÓRICO……5
5.1 Lavado de Dinero y Detección de Operaciones Sospechosas
5.1.1 Concepto y Etapas del Lavado de Dinero
5.1.2 Marco Normativo Internacional y Nacional
5.1.3 Monitoreo Transaccional Tradicional
5.2 Modelos de Aprendizaje Automático para la Detección de Lavado de Dinero
5.2.1 Aprendizaje Supervisado con Clases Desbalanceadas
5.2.2 Modelos de Árboles y Potenciación de Gradiente
5.2.3 Aplicaciones en la Detección de Lavado de Dinero
5.3 Pérdida de Eficacia de los Modelos en Producción
5.3.1 Cambio de Concepto y Cambio de Datos
5.3.2 Tipos y Causas del Cambio
5.3.3 Etiquetas con Retraso
5.3.4 Detección de la Pérdida de Eficacia
5.4 Agentes de Inteligencia Artificial
5.4.1 Modelos de Lenguaje de Gran Tamaño
5.4.2 Agentes con Uso de Herramientas
5.4.3 Sistemas Multiagente y Evaluación con Juez
5.5 Trabajos Relacionados

6. METODOLOGÍA……...……...6

7. RESULTADOS Y CONCLUSIONES……...7

REFERENCIAS...…….....…….....8

APÉNDICES.....……...…….....9

ANEXOS.....……...…….....11

## ÍNDICE DE TABLAS

**Tabla.** **Página**

1. (Nombre de la Tabla) ..... **¡Error! Marcador no definido.**

2. (Nombre de la Tabla) ..... **¡Error! Marcador no definido.**

3. (Nombre de la Tabla) ..... 2

4. (Nombre de la Tabla) ..... 2

5. (Nombre de la Tabla) ..... **¡Error! Marcador no definido.**

## ÍNDICE DE FIGURAS

**Figura.** **Página**

1. (Nombre de la Figura).....**¡Error! Marcador no definido.**

2. (Nombre de la Figura).....**¡Error! Marcador no definido.**

3. (Nombre de la Figura).....2

4. (Nombre de la Figura).....2

5. (Nombre de la Figura).....**¡Error! Marcador no definido.**

## AGRADECIMIENTOS

(Aquí se escriben los agradecimientos a personas o instituciones que apoyaron la elaboración de este trabajo de investigación. Este apartado es opcional.).

# CAPÍTULO 1

# INTRODUCCIÓN

## 1.1 (Subtítulo de Primer Nivel)

1.1.1 (Subtítulo de Segundo Nivel).

Redacción alusiva al primer subtema de este capítulo. JkadkjfhkhdsfkDFLKLKJdklfj.

Nfdkjdksfjng.nsfd.gn .lnkfglkfg lkdjfgñlkjsdñflkgjlkjfdg ñlsdjfglkjfdlkgj lkjglkjslkjg

1.1.1.1 (Subtítulo de Tercer Nivel).

Redacción alusiva al primer subtema de este capítulo. JkadkjfhkhdsfkDFLKLKJdklfj.

1.1.1.1.1 (Subtítulo).

Redacción alusiva al segundo subtema de este capítulo.

## 1.2 (Subtítulo)

1.2.1 (Subtítulo de Segundo Nivel).

Redacción alusiva al primer subtema de este capítulo.

1.2.1.1 (Subtítulo de tercer nivel).

Redacción alusiva al segundo subtema de este capítulo.

# CAPÍTULO 2

## DELIMITACIÓN Y PLANTEAMIENTO DEL PROBLEMA DE INVESTIGACIÓN

De acuerdo con Albanese (2012) todas las entidades que pretenden perdurar en el tiempo se enfrentan a cambios radicales en las demandas políticas, sociales, tecnológicas y, sobre todo, al surgimiento de técnicas sofisticadas de fraude. Entre los riesgos que estas técnicas plantean destaca el lavado de dinero, entendido como el proceso en virtud del cual los bienes de origen delictivo se integran en el sistema económico legal aparentando haber sido obtenidos de forma lícita (Blanco Cordero, 1997, p. 101). Su detección comenzó en la década de 1970, cuando las instituciones financieras empezaron a reportar transacciones al gobierno, pero quienes lavan dinero han mostrado adaptabilidad para encontrar nuevos canales, como los sitios web comerciales y los sistemas de pago por internet (Rocha-Salazar et ál., 2021). Se estima que cada año se lava entre 2% y 5% del producto interno bruto mundial, es decir, entre 800 mil millones y 2 billones de dólares (United Nations Office on Drugs and Crime [UNODC], s.f.). Este delito debilita la integridad del sistema financiero, provoca la pérdida de control de los países sobre sus políticas económicas, distorsiona la economía y reduce la recaudación fiscal (Rocha-Salazar et ál., 2021). Identificar estas operaciones exige reconocer patrones que ya no responden a esquemas estáticos.

Ante este panorama, la respuesta internacional ha sido establecer estándares normativos. El Grupo de Acción Financiera Internacional (GAFI) es un organismo intergubernamental independiente que desarrolla y promueve políticas para proteger el sistema financiero global contra el lavado de dinero, el financiamiento del terrorismo y el financiamiento de la

proliferación de armas de destrucción masiva, y sus recomendaciones son reconocidas como el estándar global en la materia (Financial Action Task Force [FATF], 2022). Los avances normativos son notables: el cumplimiento técnico de las jurisdicciones evaluadas pasó de 36% en 2012 a 76% (FATF, 2022, p.5). Sin embargo, solo el 21% alcanza un nivel promedio de efectividad alto o sustancial (FATF, 2022, p.11). Por lo tanto, tener normas no garantiza que funcionen, y ello vuelve decisivo el instrumento con el que las instituciones identifican las operaciones sospechosas. Durante décadas ese instrumento fueron reglas fijas con umbrales predefinidos, pero la disponibilidad de grandes bases de datos, el mayor poder de cómputo y el desarrollo de paquetes de software llevaron a incorporar técnicas de inteligencia artificial para superar las deficiencias de los métodos tradicionales (Rocha-Salazar et ál., 2021).

Este esfuerzo internacional se vio reflejado en México de manera gradual: en 1990 se incorporó el delito de lavado de dinero al Código Fiscal de la Federación, se emitieron las primeras disposiciones generales para el sistema financiero y, en 2000, el país ingresó como miembro de pleno derecho al GAFI (Núñez Camacho, 2008, pp. xxi-xxii). En la actualidad, el marco institucional integra a la Secretaría de Hacienda y Crédito Público, por medio de la Unidad de Inteligencia Financiera (UIF), al Banco de México y a los supervisores del sistema financiero, entre ellos la Comisión Nacional Bancaria y de Valores (CNBV) (UIF, 2023, pp. 10-11). Para las instituciones financieras en México, ese marco se traduce en la obligación de contar con sistemas automatizados que detecten y monitoreen operaciones, generen alertas y sustenten el reporte de operaciones inusuales (CNBV, 2017, diap. 25 y 31). Sin embargo, la Evaluación Nacional de Riesgos reconoce deficiencias en estos sistemas, principalmente en la parametrización de sus escenarios de alerta (UIF, 2023, p. 23).

Las deficiencias señaladas en la configuración de las alertas no son el único riesgo: aun configuradas bien, los modelos que detectan operaciones sospechosas pierden eficacia con el tiempo, porque cambian los datos y también las formas de operar de quienes lavan dinero (Gama et ál., 2014; Rocha-Salazar et ál., 2021). Además, hay que confirmar que una operación fue realmente lavado de dinero y esto puede tardar meses, por lo que esa pérdida suele notarse tarde (Sethi et ál., 2026). Esto plantea dos necesidades: detectar a tiempo que un modelo dejó de funcionar como se espera y comprender a qué se debe, para poder actuar. Atenderlas implica examinar evidencia y razonar sobre ella, labor en la que los agentes de inteligencia artificial, programas capaces de consultar herramientas de análisis y de razonar sobre sus resultados, han mostrado utilidad para diagnosticar fallas en plataformas en la nube (Wang et ál., 2024). Por ello, este trabajo se delimita a vigilar un modelo de detección de lavado de dinero, avisar cuándo pierde eficacia y explicar su causa mediante agentes de inteligencia artificial, y a contrastarlo con el monitoreo tradicional, basado en reglas y umbrales fijos; quedan fuera el financiamiento al terrorismo, la modificación automática del modelo y el reporte de operaciones a la autoridad. De ahí surge la siguiente pregunta de investigación:

¿En qué medida un sistema de agentes de inteligencia artificial puede detectar a tiempo y explicar la pérdida de eficacia de un modelo de detección de lavado de dinero, en comparación con el monitoreo tradicional?

# CAPÍTULO 3

# JUSTIFICACIÓN

En México, la Comisión Nacional Bancaria y de Valores (CNBV) impuso 220.4 millones de pesos en multas por prevención de lavado de dinero en 2024 y 359.0 millones en 2025, frente a 82.9 millones en 2023, lo que equivale a multiplicar por 4.3 el monto en dos años y a casi un tercio de todas las multas de 2025 (CNBV, 2026; cálculos propios). Entre las causas figuran deficiencias en los sistemas automatizados de detección, monitoreo y reporte de operaciones (CNBV, 2026). Estos sistemas automatizados generan una enorme cantidad de alertas, señales que un analista debe revisar porque una operación cumplió una regla predefinida, y más de 98% de ellas pueden ser falsos positivos, es decir, operaciones que al revisarse no resultan sospechosas (Jensen y Iosifidis, 2023). En una institución financiera de EE. UU., solo 34 de 6,113 alarmas se reportaron a las autoridades (Zhang y Trubey, 2019, como se citó en Jensen y Iosifidis, 2023). Así, ya sea por no vigilar lo suficiente o por saturarse de alertas, un sistema de detección que no se supervisa deja pasar lavado y desperdicia recursos.

Atender este problema de manera temprana beneficia a las instituciones financieras, a los analistas de cumplimiento y a la sociedad. Para las instituciones financieras, enterarse a tiempo de que su modelo dejó de funcionar como se espera reduce el riesgo de sanciones y de que operaciones de origen ilícito pasen sin ser detectadas. Para los analistas de cumplimiento, recibir además una explicación de la causa les permitiría decidir con mayor rapidez qué corregir, en un trabajo que hoy se ve saturado de alertas (Jensen y Iosifidis, 2023). Finalmente, la sociedad se beneficia porque se dificulta la

actividad de quienes lavan dinero y se protege la integridad del sistema financiero (Rocha-Salazar et ál., 2021). Estos beneficios aplican a las instituciones que ya utilizan modelos para detectar operaciones sospechosas.

El uso de agentes y modelos de lenguaje para combatir el lavado de dinero se ha centrado en detectar operaciones sospechosas (Mohamed et ál., 2026; Pirmorad, 2025), mientras que, la pérdida de eficacia de los modelos con el paso del tiempo se ha enfocado en el fraude sin recurrir a agentes (Sethi et ál., 2026). Este estudio aportaría evidencia sobre en qué medida un enfoque basado en agentes para explicar el deterioro del modelo supera al monitoreo tradicional.

La realización de este estudio es viable. Dado que uno de los principales obstáculos para la investigación del lavado de dinero es la escasez de conjuntos de datos públicos (Jensen y Iosifidis, 2023), una alternativa son los conjuntos de datos sintéticos de transacciones, calibrados con transacciones reales y con las operaciones de lavado plenamente identificadas (Altman et ál., 2023). Al tratarse de datos simulados, los resultados se interpretarán como evidencia en un entorno controlado y no como el desempeño que tendría el sistema en una institución financiera real.

# CAPÍTULO 4

# FORMULACIÓN DE OBJETIVOS

## 4.1 Objetivo General

Evaluar en qué medida un sistema de agentes de inteligencia artificial detecta a tiempo y explica la pérdida de eficacia de un modelo de detección de lavado de dinero, en comparación con el monitoreo tradicional basado en reglas y umbrales fijos, en un entorno de producción simulado, para aportar evidencia sobre su utilidad en la vigilancia de estos modelos.

## 4.2 Objetivos Específicos

Establecer escenarios simulados en los que un modelo de detección de lavado de dinero pierde eficacia por causas conocidas, para contar con referencias contra las cuales verificar la detección y el diagnóstico.

Determinar el tiempo con que el sistema de agentes detecta la pérdida de eficiencia y la proporción de causas que identifica correctamente, para medir su oportunidad y exactitud.

Contrastar el desempeño del sistema de agentes con el del monitoreo tradicional en esos mismos escenarios, para identificar en qué condiciones ofrece una ventaja.

# CAPÍTULO 5

# MARCO TEÓRICO

## 5.1 Lavado de Dinero y Detección de Operaciones Sospechosas

5.1.1 Concepto y Etapas del Lavado de Dinero
5.1.2 Marco Normativo Internacional y Nacional
5.1.3 Monitoreo Transaccional Tradicional

## 5.2 Modelos de Aprendizaje Automático para la Detección de Lavado de Dinero

5.2.1 Aprendizaje Supervisado con Clases Desbalanceadas
5.2.2 Modelos de Árboles y Potenciación de Gradiente
5.2.3 Aplicaciones en la Detección de Lavado de Dinero

## 5.3 Pérdida de Eficiencia de los Modelos en Producción

5.3.1 Cambio de Concepto y Cambio de Datos
5.3.2 Tipos y Causas del Cambio
5.3.3 Etiquetas con Retraso
5.3.4 Detección de la Pérdida de Eficiencia

## 5.4 Agentes de Inteligencia Artificial

5.4.1 Modelos de Lenguaje de Gran Tamaño
5.4.2 Agentes con Uso de Herramientas
5.4.3 Sistemas Multiagente y Evaluación con Juez

## 5.5 Trabajos Relacionados

# CAPÍTULO 6

# METODOLOGÍA

## 6.1 (Subtítulo de Primer Nivel)

6.1.1 (Subtitulo de Segundo Nivel).

Redacción alusiva al primer subtema de este capítulo.

6.1.1.1 (Subtítulo de Tercer Nivel).

Redacción alusiva al segundo subtema de este capítulo.

6.1.1.1.1 (Subtítulo de Cuarto Nivel).

Redacción alusiva al segundo subtema de este capítulo.

# CAPÍTULO 7

# RESULTADOS Y CONCLUSIONES

## 7.1 (Subtítulo)

7.1.1 (Subtitulo).

Redacción alusiva al primer subtema de este capítulo.

7.1.1.1 (Subtítulo).

Redacción alusiva al segundo subtema de este capítulo.

7.1.1.1.1 (Subtítulo).

Redacción alusiva al segundo subtema de este capítulo.

# APÉNDICES

# ANEXOS

## REFERENCIAS


Albanese, D. (2012). Análisis y evaluación de riesgos: aplicación de una matriz de riesgo en el marco de un plan de prevención contra el lavado de activos. *Base*. http://repositoriodigital.uns.edu.ar/handle/123456789/4099

Blanco Cordero, I. (1997). *El delito de blanqueo de capitales*. Aranzadi.

United Nations Office on Drugs and Crime. (s.f.). *Overview*. Consultado el 5 de octubre de 2026. https://www.unodc.org/unodc/en/money-laundering/overview.html

Rocha-Salazar, J.-d.-J., Segovia-Vargas, M.-J. y Camacho-Miñano, M.-d.-M. (2021). Money laundering and terrorism financing detection using neural networks and an abnormality indicator. *Expert Systems with Applications.*

Financial Action Task Force. (2022). *Report on the state of effectiveness and compliance with the FATF standards*.

Comisión Nacional Bancaria y de Valores. (2017). *El lavado de dinero y el financiamiento al terrorismo* [Diapositivas de PowerPoint].

Núñez Camacho, M. de la L. (2008). *El fenómeno de lavado de dinero en México: Causas, efectos y propuestas para reforzar su combate*. Porrúa.

Unidad de Inteligencia Financiera. (2023). *Evaluación nacional de riesgos de lavado de dinero y financiamiento al terrorismo 2023*. Secretaría de Hacienda y Crédito Público.

Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M. y Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys, 46*(4), Artículo 44.

Comisión Nacional Bancaria y de Valores. (2026). *Registro de sanciones administrativas*. Recuperado el 14 de octubre de 2026, de https://sanciones.cnbv.gob.mx

Jensen, R. I. T. y Iosifidis, A. (2023). Fighting money laundering with statistics and machine learning. *IEEE Access, 11*, 8889-8903

Mohamed, R. E., Hussain, M., Jadidi, Z., Foo, E. y Azam, S. (2026). Towards agentic AI swarm modeling for blockchain-based money laundering detection. En S. Pal, K. Biswas, S. Kanhere, T. Myers y V. Muthukkumarasamy (Eds.), *Distributed ledger technology: SDLT 2025* (Communications in Computer and Information Science, Vol. 2892, pp. 232-250). Springer

Pirmorad, E. (2025). *Exploring the in-context learning capabilities of LLMs for money laundering detection in financial graphs* [Preprint]. arXiv. https://arxiv.org/abs/2507.14785

Sethi, A., Gupta, P., Kansotia, S., Kant, K. y Srivasatava, N. (2026). Proactive detection of model degradation in financial fraud prediction with delayed labels. En *Machine learning and knowledge discovery in databases: Applied data science track (ECML PKDD 2025)* (pp. 265-281). Springer.

Wang, Z., Liu, Z., Zhang, Y., Zhong, A., Wang, J., Yin, F., Fan, L., Wu, L. y Wen, Q. (2024). RCAgent: Cloud root cause analysis by autonomous agents with tool-augmented large language models. En *Proceedings of the 33rd ACM International Conference on Information and Knowledge Management (CIKM '24)*. ACM.

**Altman, E., Blanuša,** J., von Niederhäusern, L., Egressy, B., Anghel, A. y Atasu, K. (2023). Realistic synthetic financial transactions for anti-money laundering models. En *Advances in Neural Information Processing Systems 36 (NeurIPS 2023), Datasets and Benchmarks Track*.